



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
INSTITUTO DE INGENIERÍA MATEMÁTICA Y COMPUTACIONAL
IMT2270 - PROYECTO FINAL DE GRADO

Diagnóstico de la calidad de los datos

4 de septiembre de 2025

Franco Chiappe - Vicente Garay - Ziyu Guo

Introducción

El control de calidad de los datos en las plantas de tratamiento actualmente se realiza de forma manual y reactiva. Esto genera retrasos en la detección de fallas, valores atípicos y descalibraciones de sensores, así como cambios de distribución (*drift*). Además, no existen indicadores formales que midan la calidad de los datos que ingresan a la plataforma, lo cual impacta directamente en la confiabilidad y precisión de los modelos predictivos.

Ante esta situación, surge la necesidad de diseñar un sistema automático de evaluación de calidad de datos que permita detectar anomalías, drift y fallas en los sensores, generando indicadores útiles para la toma de decisiones y la operación eficiente de las plantas. De esta manera, el presente informe constituye un insumo inicial para avanzar hacia un sistema automatizado de monitoreo de calidad de datos.

Antes de continuar, definamos dos conceptos clave que guiarán este análisis:

- **Outlier:** valor que se desvía de manera significativa respecto de la distribución esperada o del rango físico posible, y que no corresponde al patrón habitual de la variable.
- **Drift:** presencia de cambios estructurales en la distribución de una variable a lo largo del tiempo, los cuales no pueden atribuirse únicamente al ruido natural de la señal ni a valores atípicos puntuales.

Objetivo del Informe

Este documento corresponde a la primera etapa del proyecto, enfocada en realizar un diagnóstico exploratorio de los datos históricos de las plantas. El propósito es identificar patrones, estacionalidades, valores atípicos, lagunas y posibles señales de drift en las principales variables, de modo de caracterizar el estado actual de la información disponible.

Los resultados de este diagnóstico servirán como insumo para la definición de métricas de calidad, el diseño del sistema de evaluación automática y la validación de los métodos de detección de anomalías.

Los objetivos específicos de este informe son:

- Evaluar la calidad de los datos mediante un análisis exploratorio de variables representativas.
- Documentar problemas recurrentes (valores atípicos, ausencia de datos, distribuciones inusuales).
- Identificar oportunidades de mejora y criterios iniciales para la construcción de indicadores de calidad.

Exploración preliminar

Se revisaron algunas variables de interés de manera general. La totalidad de las variables se encuentran disponibles en el repositorio del proyecto: GitHub – Proyecto de Grado.

En este informe se presentan ejemplos representativos, en caso de que se desee revisar otra variable específica, el análisis detallado puede encontrarse en los *notebooks* de Jupyter incluidos en dicho repositorio.

Análisis exploratorio

Luego de esta revisión preliminar, se realiza un análisis más detallado de los datos, organizado por planta. Para cada caso se presenta una tabla con las variables disponibles y su periodicidad de muestreo, seguida de una matriz de correlación que permite identificar relaciones lineales entre variables. Estas matrices son útiles para detectar redundancias, dependencias funcionales y patrones atípicos que puedan afectar la calidad del dato.

A continuación, se incluyen visualizaciones individuales de variables seleccionadas por su relevancia operativa y por la presencia de anomalías significativas, tales como valores atípicos, lagunas de datos o indicios de drift. Estas visualizaciones permiten ilustrar los principales problemas de calidad presentes en los datos históricos.

Planta 1: pH Coagulación, Ecualizador y DAF

La primera planta analizada corresponde a una etapa crítica del tratamiento de aguas, donde se monitorean variables asociadas a la coagulación, ecualización y flotación por aire disuelto (DAF). Estas variables incluyen niveles, flujos, pH, temperatura y turbidez, los cuales influyen directamente en la eficiencia del proceso y en el cumplimiento normativo.

El objetivo del análisis es identificar posibles anomalías, redundancias o inconsistencias en los registros que puedan afectar el control operacional. Para ello, se presenta primero una tabla con las variables disponibles, seguida de una matriz de correlación y un análisis detallado de algunas variables seleccionadas.

Cuadro 1: Variables y periodicidad (P1)

nombre	unidad	periodicidad
Conductividad	mS/cm	1 minutos
Conductividad DAF	mS/cm	1 minutos
Fecha	Dia	1 minutos
Flujo Parshall 01 entrada a Ecualizador 1	m3/hr	1 minutos
Flujo de envío a DAF	m3/hr	1 minutos
Hora	min	1 minutos
Nivel Ecualizador 1 (Tk 30m3)	%	1 minutos
Nivel Ecualizador 2 (Tk 250m3)	%	1 minutos
PH Coagulación	-	1 minutos
Temperatura DAF	°C	1 minutos
pH Clarificado DAF (Tk 80m3)	-	1 minutos
pH Clarificado DAF (Tk 80m3)	-	1 minutos
pH Ecualizador 2 (Tk 250m3)	-	1 minutos
pH clarificado DAF	-	1 minutos
pH coagulación entrada DAF	-	1 minutos
pH coagulación DAF	-	1 minutos
pH de salida a Parshall 02	-	1 minutos
pH entrada a Ecualizador 2 (Tk 250m3)	-	1 minutos
pH salida a Parshall 02	-	1 minutos
pH salida a Parshall 02	-	1 minutos
Nivel Clarificado DAF (Tk 80m3)	%	1 minutos
PH Descarga	-	1 minutos
pH entrada a Ecualizador 1	-	1 minutos
Nivel Clarificado DAF (Tk 80m3)	%	1 minutos
Turbidez salida DAF	NTU	1 minutos
Caudal Descarga	m3/hr	1 minutos
pH salida y control Ecualizador 1	-	1 minutos




Figura 1: Matriz de correlación – Planta 1

En términos generales, la mayoría de los coeficientes de correlación no son relevantes, pues provienen de variables con poca variabilidad en el tiempo. Sin embargo, destaca la fuerte relación entre “*Nivel Ecualizador 1 (Tk 30 m³)*” y “*Nivel Ecualizador 2 (Tk 250 m³)*”, la cual resulta útil para la detección de outliers.

Posteriormente, se examina con mayor detalle el comportamiento individual de un conjunto reducido de variables. La selección responde a dos criterios principales. Su relevancia operativa dentro del proceso y la presencia de anomalías potenciales que permiten ilustrar las problemáticas de calidad de datos más frecuentes.

pH Coagulación




Figura 2: Gráfica ph coagulación entrada DAF

En estas gráficas se observa el comportamiento de la variable “*pH coagulación entrada DAF*”. En la serie temporal (a) se muestran también los límites de advertencia definidos por normativa.

El comportamiento es relevante porque no presenta estacionaridad ni estacionalidad. Además, entre junio y julio se evidencia una ausencia de datos que resulta preocupante, considerando que, según las normativas **NCh 409/01:2005** y **NCh 409/02:2004**, ciertos parámetros deben ser registrados y cumplir rangos específicos.

Respecto a los outliers, algunos son muy evidentes: el pH solo puede tomar valores entre 0 y 14, sin embargo, aparecen registros mayores o iguales a 14. También se observan caídas abruptas, aunque no es posible clasificarlas como outliers a simple vista; este aspecto será evaluado con más detalle más adelante.

Nivel Ecualizador 2




Figura 3: Gráfica nivel Ecualizador 2

En este caso se observa un comportamiento oscilatorio amplio, sin outliers claros a simple vista, aunque persiste el problema de la laguna de datos.

Flujo Parshall 01 entrada a Ecualizador 1




Figura 4: Gráfica Flujo Parshall 01

Por último vemos el *Flujo Parshall 01 entrada a Ecualizador 1*. Su comportamiento se asemeja a una distribución estadística conocida, posiblemente log-normal, aunque sería necesario realizar ajustes estadísticos para confirmarlo. A simple vista presenta valores alejados del resto, pero que aumentan de manera progresiva, es decir, sin salto abruptos.

Planta 2: Flujos, Nivel y Pozo WAS

La segunda planta se centra en procesos de tratamiento biológico y manejo de lodos. Las variables registradas incluyen flujos de entrada y salida en distintas etapas, niveles de pozos y concentraciones de oxígeno disuelto (OD) en reactores. Estas mediciones permiten evaluar el desempeño del sistema y anticipar fallas operativas.

El análisis busca detectar comportamientos anómalos, lagunas de datos y correlaciones útiles para validaciones cruzadas. A continuación, se presenta la tabla de variables disponibles, seguida de la matriz de correlación y un análisis más específico de variables representativas.

Cuadro 2: Variables y periodicidad (P2)

nombre	unidad	periodicidad
Flujo Afluente PTAR	L/s	1 minutos
Flujo Cámara de contacto 1	L/s	1 minutos
Flujo Cámara de contacto 2	L/s	1 minutos
Flujo Alimentación Digestor 1	L/s	1 minutos
Flujo Alimentación Digestor 2	L/s	1 minutos
Flujo Alimentación Digestor 3	L/s	1 minutos
Nivel Pozo WAS	m	1 minutos
Flujo Salida de Lodo Sedimentador Secundario 3	L/s	1 minutos

nombre	unidad	periodicidad
Flujo Aire Reactor 1	L/s	1 minutos
Flujo Aire Reactor 2	L/s	1 minutos
Flujo Aire Reactor 3	L/s	1 minutos
OD Reactor 1	mg/l	1 minutos
OD Reactor 2	mg/l	1 minutos




Figura 5: Matriz de correlación – Planta 2

En general, se observan correlaciones fuertes, principalmente entre variables ON/OFF simultáneas y flujos estrechamente relacionados. Este patrón facilita la detección de outliers y la validación cruzada de registros.

Posteriormente, se analizan de manera individual algunas variables seleccionadas por su relevancia operativa y por la presencia de anomalías que ilustran problemas frecuentes en la calidad de datos.

Flujo salida de Lodo Sedimentador Secundario 3




Figura 6: Gráfica Flujo salida de Lodo Sedimentador Secundario 3

Se aprecia alta variabilidad y presencia de lagunas de datos, lo cual es crítico, ya que esta variable debería mantenerse dentro de rangos regulados. Además, se observan valores repetidos en la parte superior de la distribución, lo que sugiere fallas de registro o saturación del sensor.

Nivel Pozo WAS




Figura 7: Gráfica Nivel Pozo

El nivel del pozo muestra alta variabilidad y lagunas temporales de datos. Se identifican uno o dos valores claramente alejados del rango habitual, que pueden clasificarse como outliers. Estos registros anómalos requieren validación, pues podrían corresponder tanto a fallas de lectura como a eventos operativos atípicos.

Flujo Cámara de contacto 2




Figura 8: Grafica Flujo Cámara de contacto 2

Esta variable presenta alta variabilidad, con algunos valores extremos aislados. Su distribución es relativamente estable y reconocible, lo que resulta útil para detectar posibles casos de *drift* en caso de que la media se desplace con el tiempo.

Planta 3: Pozo y Bombas Elevadoras

La tercera planta corresponde a un sistema de bombeo, en el cual se monitorean variables operativas del pozo, como nivel, presión, fallas, y el consumo energético de las bombas. Estas variables permiten evaluar tanto el estado del pozo como el comportamiento de los equipos involucrados.

Cuadro 3: Variables y periodicidad (P3)

nombre	unidad	periodicidad
Falla Pozo	ON/OFF	1 minutos
Funcionando Pozo	ON/OFF	1 minutos
Nivel pozo	m	1 minutos
Falla Asimetría Pozo	ON/OFF	1 minutos
Presión pozo	bar	1 minutos
Nivel Pozo	m	1 minutos
Energía Total Activa Bombas Elevadoras	kWh	1 minutos






Figura 9: Matriz de correlación – Planta 3

Se destaca la correlación entre “*Presión Pozo*” y “*Energía Total Activa Bombas Elevadoras*”, aunque no necesariamente refleja una relación funcional directa, ya que presentan comportamientos disímiles en sus respectivas series temporales.

Nivel Pozo



(a) Serie Nivel Pozo



(b) Densidad Nivel Pozo

Figura 10: Gráfica Nivel Pozo

El nivel del pozo muestra un valor inicial anómalo, seguido por una variabilidad relativamente constante. Este comportamiento facilita la detección de outliers, ya que se establece un rango operativo claro. No se evidencian cambios estacionales ni tendencia marcada.

Presión Pozo




Figura 11: Gráfica Presión Pozo

La presión del pozo permanece estable durante un periodo prolongado y luego presenta un salto abrupto. Este cambio puede asociarse a una recalibración, mantenimiento o falla en el sensor. No se observan valores extremos fuera del rango físico esperado, pero el cambio súbito sugiere un posible evento de drift o discontinuidad operacional.

Outliers




Figura 12: Outliers pH - Planta 1

En estas gráficas vemos dos tipos de outliers, en rojo son outliers claros. Esto se debe a la naturaleza de las variables, ya que los valores de ph van de 0 a 14. Por lo tanto los valores en rojo (valores mayores a 14) son outliers.

Por otro lado los valores en naranja son posibles outliers, para estos puntos utilizamos un z-score robusto, útil para densidades asimétricas, con media constante y sin tanta variabilidad. Esto es solo un ejemplo de un método, se agregaran más y en detalle para el Hito 2.




Figura 13: Outlier Entrada ecualizador 2 - Planta 1

Este es un ejemplo de que este método no sirve para todos los datos, ya que no tiene una media constante, esto motiva a buscar otras formas de detectar outliers.

Viendo los datos es útil trabajar con la diferencia, pero esto lo veremos en el hito 2.

Drift

Para este informe se aplicó el test de Kolmogorov-Smirnov (KS) sobre ventanas deslizantes, comparando cada intervalo con el inmediatamente anterior. Este enfoque permite identificar desplazamientos significativos en la distribución de los datos. En el caso de la Planta 1, se omitieron los primeros días del registro para evitar que los resultados se vieran distorsionados por outliers evidentes e incluso valores imposibles observados en varias variables durante ese periodo inicial.

Planta 1 – Flujo de envío a DAF




Figura 14: Drift detectado en la variable *Flujo de envío a DAF*

En la Figura 14 se identifican periodos con una desviación marcada respecto del comportamiento habitual de la variable. Al contrastar estos resultados con el resto de sensores de la planta, se observa que en las mismas fechas aparecen picos en otras mediciones. Esto sugiere que los eventos no corresponden a fallas aisladas, sino más bien a la ejecución de procesos operativos específicos. Dichos episodios tienden a ser de corta duración y posteriormente las variables regresan a sus niveles habituales.

Planta 2 – Flujo Alimentación Digestor 1




Figura 15: Drift detectado en la variable *Flujo Alimentación Digestor 1*

En el caso de la Planta 2, la Figura 15 muestra una detección más ajustada, en la que los periodos señalados coinciden efectivamente con cambios drásticos en los valores de la variable. Esto refuerza la idea de que el método aplicado va en la dirección correcta, ya que permite capturar eventos relevantes sin marcar en exceso fluctuaciones menores. De esta manera, los resultados sirven como guía para seguir afinando los criterios de detección de drift en etapas posteriores del proyecto.

Lagunas de datos

El análisis de lagunas de datos busca identificar periodos en los cuales no se registraron mediciones, lo que puede deberse a fallas de comunicación, problemas en los sensores o detenciones de planta. La importancia de este análisis radica en que lagunas extensas o recurrentes afectan la detección de anomalías y reducen la confiabilidad de los modelos predictivos que dependen de series temporales continuas.

Planta 1

En la Planta 1 se identificó una laguna prolongada de aproximadamente 14 días, probablemente asociada a la detención del proceso. Sin embargo, también interesa evaluar lagunas más cortas, como la ausencia de datos durante 30 minutos o menos, ya que estas pueden pasar desapercibidas y afectar el análisis.

Para el mes de agosto, no se detectaron interrupciones mayores a una hora. El máximo intervalo sin datos fue de 7 minutos, mientras que el promedio entre registros fue de 1,21 minutos con una desviación estándar de 0,41 minutos.




Figura 16: Tiempo entre datos recibidos – Planta 1

En la Figura se observa que la mayoría de los intervalos corresponden a 1 minuto, con algunas repeticiones de 2 minutos, lo que confirma una frecuencia de muestreo estable.

Planta 2

En la Planta 2 el comportamiento fue diferente. Analizando el mes de junio, se observó un periodo de 203 minutos (poco más de 3 horas) sin registros, lo que impacta de manera directa la continuidad de la serie temporal.

En promedio, el intervalo entre mediciones fue también de 1,21 minutos, aunque con una desviación estándar más alta (1,34 minutos) debido a este evento prolongado.




Figura 17: Tiempo entre datos recibidos – Planta 2

La Figura muestra una distribución parecida a la de Planta 1, con predominio de intervalos de 1 minuto, pero con mayor frecuencia en 2 y 4 minutos. Esto indica que, aunque la planta mantiene un registro regular, los periodos de interrupción son más largos y variables que en Planta 1.

Conclusión

El presente informe permitió realizar un diagnóstico inicial de la calidad de los datos provenientes de las tres plantas de tratamiento. A partir del análisis exploratorio se identificaron patrones

generales, correlaciones, outliers evidentes, eventos de drift y lagunas de datos de distinta magnitud.

Entre los principales hallazgos destacan:

- La presencia de valores atípicos claros, en particular en variables de pH, que sobrepasan los rangos físicos posibles (0–14) y que requieren filtros de validación más estrictos.
- Episodios de drift detectados en variables de flujo, los cuales coinciden en varios sensores y sugieren cambios operativos puntuales más que fallas individuales.
- Lagunas de datos extensas en ciertas plantas (hasta 14 días en P1 y 3 horas en P2), que afectan la continuidad temporal y deben considerarse en el diseño de imputación o mecanismos de alerta temprana.

Este diagnóstico constituye una base sólida para las siguientes etapas del proyecto. En particular, orienta la selección de modelos de detección de anomalías. Igualmente, los resultados sobre lagunas de datos permiten planificar estrategias de tratamiento de datos faltantes, desde imputaciones simples hasta enfoques adaptativos según la duración de la interrupción.

En conclusión, el análisis exploratorio realizado confirma la existencia de problemas críticos de calidad de datos en las tres plantas y resalta la necesidad de un sistema automático de monitoreo. El avance alcanzado en este hito entrega una primera caracterización de dichos problemas y orienta la definición de métricas, la elección de métodos y las pruebas que se desarrollarán en el próximo Hito 2.