



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
INSTITUTO DE INGENIERÍA MATEMÁTICA Y COMPUTACIONAL
IMT2270 - PROYECTO FINAL DE GRADO

Diagnóstico de la calidad de los datos

31 de octubre de 2025

Franco Chiappe - Vicente Garay - Ziyu Guo

1. Introducción

En el Hito 1 se realizó un diagnóstico exploratorio del estado actual de los datos históricos de las tres plantas de tratamiento, identificando patrones, outliers, drift y lagunas. Ese análisis permitió reconocer los principales focos de degradación en la calidad de los datos y sentó las bases para la construcción de un sistema de monitoreo continuo.

El presente Hito 2 tiene por objetivo establecer métricas cuantitativas y umbrales de severidad que permitan evaluar la calidad de los datos de manera objetiva y reproducible. A partir de estas métricas se busca definir criterios automáticos de alerta que diferencien errores leves, eventos críticos o desviaciones progresivas en los sensores industriales de las plantas Ainwater.

2. Objetivo

Definir un conjunto de métricas e indicadores que permitan evaluar objetivamente la calidad de los datos provenientes de sensores industriales, orientados al monitoreo en línea y la detección temprana de anomalías operativas.

Objetivos específicos

- Proponer métricas para medir validez, consistencia y estabilidad de los datos.
- Establecer umbrales y niveles de severidad.
- Justificar la relevancia de cada métrica en el contexto de operación de las plantas.
- Aplicar las métricas sobre datos reales para validar su utilidad práctica.

3. Metodología general

3.1 Enfoque general del sistema de monitoreo

El sistema de monitoreo de calidad de datos se compone de una secuencia de etapas que permiten procesar, evaluar y reportar el estado de las mediciones provenientes de los sensores industriales. Primero se ejecuta un módulo de ETL (extracción, transformación y carga) que normaliza los formatos temporales, corrige lagunas y filtra valores imposibles. Luego, los datos limpios son procesados por modelos de detección de outliers y detección de drift; ambos resultados alimentan las métricas de calidad definidas en este Hito 2 e informan las decisiones operativas.

El proceso opera sobre ventanas temporales dinámicas y aplica los siguientes pasos:

- Definir ventana actual (`CURRENT_WINDOW`) y cargar datos crudos del rango requerido.
- ETL y limpieza: normalización temporal, corrección de lagunas cortas, filtros de valores imposibles y exclusión de `EXCLUDE_COLUMNS`.
- Detección de outliers (módulos `AR` / `DIFF`): generar máscaras de outliers y scores por punto/intervalo para su uso en reportes y para contextualizar el drift.
- (Opcional) Re-muestreo: aplicar `RESAMPLE` y `RESAMPLE_AGG` para estabilizar ruido y tamaños muestrales.
- Construcción de referencia de drift: elegir una estrategia (`Decay`, `Golden`, `Seasonal`) y generar la distribución histórica de comparación.
- Cálculo de métodos estadísticos de drift: evaluar `KS`, `PSI`, `Wasserstein` y/o `Mann-Whitney` entre ventana actual y referencia para obtener drift scores.
- Integración drift-outliers: (i) anotar si las ventanas contienen episodios con alta densidad de outliers; (ii) ofrecer variantes de cálculo robustas (p. ej., exclusión de picos aislados o agregación robusta) para distinguir drift real de drift inducido por outliers.
- Agregación y tasa de drift: resumir por columna y estrategia, calcular `drift_rate_%` y generar tablas/gráficos por planta.
- Contexto operacional: registrar coberturas, tamaños muestrales efectivos, exclusiones y eventos de operación para interpretar resultados.

3.2 Modelos de detección de Outliers

Primero veamos los predictores que utilizaremos para la detección de outliers:

- Serie de tiempo: Este modelo se basa en ajustar un modelo de serie de tiempo, ejemplo: `AR`, `ARMA`, `ARIMA`, etc. Y después ver los residuos del modelo (cuanto se aleja la predicción del valor real)

- Diferenciación estadística: Este modelo se basa en analizar la diferencia del dato con su predecesor y su sucesor, para después comparar con las diferencias históricas en la serie.

3.2.1 Basado en modelos de serie de tiempo

Este enfoque ajusta un modelo autorregresivo (p.ej. $AR(p)$) sobre la serie y utiliza los **residuos** para construir un *outlier score* y un *change score* (detección de cambios en patrón operativo) con parámetros de suavizado y umbrales por cuantiles. A continuación se detallan los supuestos, parámetros y la forma de cálculo del puntaje, tal como se implementó en el proyecto.

Este modelo se basa en (Yamanishi & Takeuchi, 2006), el paper habla de un modelo unificado para la detección de outliers. entrega un outlier score y un change score

El modelo necesita ciertos parámetros para ser entrenado, primero pide un modelo de serie de tiempo, en este caso utilicé el modelo $AR(2)$, este puede cambiar según cada variable, no necesita ser un modelo en específico.

Por otro lado el modelo pide:

- $\alpha \in [0, 1]$: Este parámetro se llama factor de suavizado, sirve para calcular la varianza dinámica de los residuos, entre más pequeño el α , más lento se actualiza la varianza.
Si bien un valor bajo es bueno, ya que tiene una larga memoria, puede empeorar el modelo ante un época con mucha variabilidad.
- $quantile \in (0, 1)$: Este parámetro pide el umbral de cuantil para clasificarlo como outlier, es decir si se entrega $quantile = 0.995$, todo punto con outlier score sobre el cuantil 0.995 será clasificado como outlier
- $factor_olvido \in (0, 1)$: Controla la rapidez con la que el algoritmo *changefinder* se adapta a nuevos datos, un valor menor (ej: 0.01) le da más peso a valores recientes, pero empeora su rendimiento cuando hay ruido. En cambio un valor más grande le da más peso al pasado, pero pierde eficacia en épocas con mayor variabilidad
- $lag_cambio \in \mathbb{Z}^+$: Para entender este parámetro, hay que entender el algoritmo *changefinder*, este funciona con un modelo AR, por lo tanto *lag_cambio* es el componente AR del algoritmo
- $suavizado \in \mathbb{Z}^+$: Es el tamaño de media móvil que aplica el algoritmo, un valor pequeño (ej: 1), puede generar ruido, en cambio un valor más grande (ej: 8) reduce falsos positivos, pero valores muy altos pueden hacer que el algoritmo demore más.
- $change_quantile \in (0, 1)$: Misma idea que *quantile* solo que se basa en el cuantil de *change_score*

Ahora que ya conocemos los parámetros, veamos como se calcula *outlier_score*:

Sea r_t :

$$r_t = x_t - \hat{x}_t$$

Es decir r_t es el error de la predicción de la serie de tiempo. Ahora veamos como se estima la varianza:

$$s_t^2 = (1 - \alpha)s_{t-1}^2 + \alpha r_t^2$$

Por último el paper asume que $r_t \sim N(0, s_t^2)$, con todo esto ya podemos ver como se calcula *outlier_score*:

$$outlier_score = \frac{1}{2}(\log(2\pi s_t^2) + \frac{r_t^2}{s_t^2})$$

La cual se basa en la menor log-verosimilitud de la densidad de r_t .

Y el *change_score* funciona con la librería *changefinder* y detecta cambios con un algoritmo basado en el error del modelo AR

Ahora hagamos un pequeño pros y contras:

- PRO: Si se tiene una serie de tiempo ajustada, no se pierde tiempo en aplicar el modelo, por ejemplo a las variables kpi nombradas en las reuniones.
- PRO: Si se ajustan bien los parámetros, el modelo ajusta bien para cambios de varianza.
- CONTRA: Pierde eficacia con variables tipo ON/OFF, habría que entrenarlo con solo datos tipo ON.
- CONTRA: Si no se tiene un modelo de serie de tiempo, habría que hacer el análisis para ajustar la mejor, llevando así tiempo y pruebas.
- CONTRA: Es débil a cambio de media, es decir si hay un cambio de media considerable, habría que entrenar el modelo de nuevo.

Ahora unas posibles mejoras:

- Entrenar una serie de tiempo más adecuada por variable, o utilizar las series de tiempo ya optimizadas de la empresa
- Agregar cierta cantidad de outliers sintéticos para encontrar el mejor threshold de *outlier_score*

3.2.2 Basado en diferenciación estadística

El siguiente modelo se basa en la diferenciación estadística, explicando de manera sencilla, lo que hace es tomar el dato, ver la menor diferencia entre el dato anterior y el siguiente y compararlo con la desviación estándar de la diferencia centrada pasada. Este utiliza dos parámetros:

- $\lambda_{centrada} \in \mathbb{Z}^+$: Este número sirve para comparar el dato con la desviación estándar pasada de la diferencia centrada, es cuantas veces tiene que estar alejado para marcarlo como outlier.
- $k \in \mathbb{Z}^+$: Misma idea que el parámetro anterior, solo que no se multiplica por la std, si no es que tanta diferencia tiene que haber con el dato anterior para marcarlo como outlier, puede ser la diferencia entre el cuantil 50 y 99, o un número definido.

Idealmente kf debe ser mayor a $\lambda_{centrada} \cdot std$

Veamos como se vería de manera matemática, siendo la data y_t :

$$\begin{aligned} x_t &= \min(|y_t - y_{t-1}|, |y_t - y_{t+1}|) \\ \text{if } x_t &\geq std \cdot \lambda_{centrada} \rightarrow \text{outlier} \\ \text{elif } |y_t - y_{t-1}| &\geq k \rightarrow \text{outlier} \end{aligned}$$

Ahora hagamos un pequeño pros y contras:

- PRO: Se puede seleccionar la std de cualquier fecha, esto ayuda a variables estacionales.
- PRO: Ajustando el $\lambda_{centrada}$ se puede reducir los falsos negativos.
- PRO: Se puede ir actualizando la std a medida que se recibe un dato
- CONTRA: Se necesita el dato siguiente.
- CONTRA: Si una época es muy variable y nunca había sucedido, el modelo puede fallar.

Ahora unas posibles mejoras:

- Tener una std global, pero ir calculando la std de las últimas 2 horas o el tiempo que uno desee, y esta es mayor, tomar la std local. Así mejorando en épocas con mayor variabilidad
- Encontrar un mejor método que comparar con la std, si bien probé métodos como: z-score, IQR y medias móviles. Ninguno obtuvo mejor rendimiento que el std, pero es probable que exista un mejor método

3.3 Modelos de detección de Drift

El drift se define como una variación significativa en la distribución estadística de una variable respecto a su comportamiento histórico. La comparación se realiza entre una ventana actual y una referencia histórica, y la diferencia se resume en un drift score calculado con distancias estadísticas, como lo pueden ser Wasserstein o Kolmogorov–Smirnov, entre otras que se pueden seleccionar. En este proyecto se implementaron tres estrategias determinísticas para construir la referencia.

3.3.1 Decay reference (exponencial)

Prioriza la historia reciente mediante pesos exponenciales. Se toma el prefijo más reciente del histórico cuya masa acumulada alcanza un umbral objetivo.

Parámetros principales:

- `DECAY_HALF_LIFE_HOURS`: tiempo de vida media de los pesos (p.ej. 24×7 horas).
- `DECAY_WEIGHT_MASS`: masa acumulada objetivo del prefijo (p.ej. 0,95).

Dado un índice temporal y el tiempo actual t , se asigna a cada observación un peso $w = \exp(-\Delta t/\tau)$ con τ definido por la vida media. Se ordena por que tan reciente es y se toma el prefijo mínimo cuya masa acumulada de w supere `DECAY_WEIGHT_MASS`.

- (+) Responde rápido a cambios recientes y no requiere etiquetas.
- (−) Puede sobre-reaccionar a ruido si la vida media es demasiado corta.

Cuándo usar. Sensores con cambios de patrón operativo frecuentes.

3.3.2 Golden reference (ventanas estables)

Construye una “ventana dorada” concatenando k ventanas históricas más estables (menor dispersión robusta), que sirven de referencia “ideal” del comportamiento.

Parámetros principales:

- `GOLDEN_WIN`: ancho de cada ventana histórica (p.ej. "30min").
- `GOLDEN_STEP`: paso entre inicios de ventana (p.ej. "10min").
- `GOLDEN_K`: cantidad de ventanas más estables a concatenar (p.ej. $k = 40$).

Para cada ventana se calcula un score robusto (mediana e IQR por columna numérica, se normaliza por mediana absoluta para evitar escalas) y se seleccionan las k ventanas con menor score.

- (+) Muy robusto a ruido y a picos aislados, excelente estabilidad del baseline.
- (−) Puede reaccionar más lento ante cambios de patrón operativo recientes.

Cuándo usar. Variables con comportamiento estacional o con ruido alto donde interesa robustez del baseline.

3.3.3 Seasonal reference (estacionalidad)

Idea. Compara la ventana actual con segmentos históricos de la misma hora del día y día de semana, dentro de un horizonte de W semanas hacia atrás.

Parámetro principal:

- **SEASONAL_WEEKS_BACK:** cantidad de semanas hacia atrás utilizadas para construir la referencia (ej.: $W = 12$).
- (+) Captura patrones cíclicos con buena precisión temporal.
- (-) Dependiente de suficiente historia y puede fallar si hay cambios operativos de calendario.

Cuándo usar. Series con patrones horarios y semanales claros (flujo, temperaturas, cargas periódicas).

3.4 Cálculo de métricas de calidad

3.4.1 Outliers

Para medir la calidad del ajuste utilizaremos métricas basadas en los true positive, false positive, true negative y false negative.

Específicamente utilizaremos las siguientes métricas:

- $Precision = \frac{TP}{TP+FP}$ es decir mide de todos los puntos marcados como outliers, cuantos realmente eran outliers
- $Recall = \frac{TP}{TP+FN}$ mide la cantidad de aciertos
- $F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$

Para esto seleccionaremos 4 variables de la planta 1 y 4 de la planta 2, tomando estas estadísticas a mano, es decir se ajustara el modelo y se revisara un gráfico por día viendo los aciertos y fallos.

Esto ya que ambos modelos se ven perjudicados cuando hay 2 o más outliers juntos, ya que solo detectan el primero.

Veamos como funcionaron los modelos, tomando datos del 06-01 hasta 08-09:

Cuadro 1: Resultados de Métricas TP, FP, FN para Modelos DIFF y AR

Modelo	Variable	TP	FP	FN
DIFF	pH coagulación entrada DAF	11 (+149)	8	2
	pH Clarificado DAF (Tk_80m3)	4	2	2
	pH salida a Parshall 02	1	1	0
	Flujo Salida de Lodo Sed. Sec. 3	27 (+245)	12	1
	Flujo Afluente PTAR	1	0	1
	Flujo Cámara de contacto 2	1	0	1
AR	pH coagulación entrada DAF	10 (+59)	12	3 (+90)
	pH Clarificado DAF (Tk_80m3)	6	15	0
	pH salida a Parshall 02	0	20	1
	Flujo Salida de Lodo Sed. Sec. 3	15 (+94)	4	13 (+151)
	Flujo Afluente PTAR	2	15	0
	Flujo Cámara de contacto 2	2	17	0

Los paréntesis indican 'nubes de outliers', es decir muchos outliers juntos, para el calculo de métricas solo se van a considerar como 1 un outlier por cada nube.

Ahora veamos las métricas obtenidas

Cuadro 2: Métricas de Evaluación (Precisión, Recall, F1) para Modelos DIFF y AR

Modelo	Variable	Precisión	Recall	F1-Score
DIFF	pH coagulación entrada DAF	0.579	0.846	0.688
	pH Clarificado DAF (Tk_80m3)	0.667	0.667	0.667
	pH salida a Parshall 02	0.500	1.000	0.667
	Flujo Salida de Lodo Sed. Sec. 3	0.692	0.964	0.806
	Flujo Afluente PTAR	1.000	0.500	0.667
	Flujo Cámara de contacto 2	1.000	0.500	0.667
AR	pH coagulación entrada DAF	0.455	0.769	0.572
	pH Clarificado DAF (Tk_80m3)	0.286	1.000	0.445
	pH salida a Parshall 02	0.000	0.000	0.000
	Flujo Salida de Lodo Sed. Sec. 3	0.789	0.536	0.638
	Flujo Afluente PTAR	0.118	1.000	0.211
	Flujo Cámara de contacto 2	0.105	1.000	0.190

En conclusión el mejor modelo es el basado en la diferenciación, es el con menor falsos positivos, y menor falsos negativos.

Si se desea se pueden obtener menor falsos negativos, ajustando un $\lambda_{centrada}$ menor, con el problema de obtener mayor falsos positivos, pero así detectando todos los outliers.

3.4.2 Drift

El drift corresponde a un cambio significativo en la distribución estadística de una variable al comparar una ventana actual con una referencia histórica. A diferencia del caso de outliers, aquí no se dispone de etiquetas que indiquen de forma inequívoca cuándo un cambio es “real”, por tanto, la evaluación se realiza de manera no supervisada y estadística.

Se utilizan cuatro métodos estadísticos principales:

- **KS / Mann–Whitney:** pruebas de hipótesis basadas en p-valores, sensibles a diferencias en forma o posición.
- **PSI:** mide divergencia entre histogramas, útil para monitoreo continuo.
- **Wasserstein:** distancia promedio entre cuantiles, capta desplazamientos graduales en la media.

KS, PSI, Wasserstein y Mann–Whitney son métodos estadísticos de comparación entre ventana actual y referencia.

Cada una se aplica sobre distintas estrategias de referencia (Decay, Golden y Seasonal), obteniendo un porcentaje de columnas con drift detectado (**drift_rate_%**) para cada combinación.

La Tabla 3 muestra el promedio de columnas con drift detectado según estrategia y método estadístico.

Cuadro 3: Drift rate promedio (%) por estrategia $\times$ métodos estadísticos para cada planta

Planta	Estrategia	KS	PSI	Wasserstein	Mann–Whitney
Planta 1	Decay	66.7	80.0	53.3	33.3
	Golden	100.0	92.3	92.3	46.2
	Seasonal	73.3	73.3	60.0	40.0
Planta 2	Decay	62.5	75.0	56.3	31.3
	Golden	85.7	92.9	89.3	50.0
	Seasonal	70.8	66.7	58.3	45.8
Planta 3	Decay	60.0	66.7	53.3	26.7
	Golden	88.2	94.1	88.2	52.9
	Seasonal	68.8	75.0	62.5	37.5

Para evaluar la coherencia entre los métodos utilizados, se calculó el porcentaje de coincidencia entre pares de métodos estadísticos, considerando las variables clasificadas con drift. La Tabla 4 muestra dicha coincidencia promedio por planta.

Cuadro 4: Coincidencia (%) entre métodos estadísticos de drift por planta

Planta	PSI–Wass.	KS–MWU	KS–PSI	KS–Wass.	MWU–PSI	MWU–Wass.
Planta 1	83.5	41.2	62.4	60.1	54.6	58.9
Planta 2	79.8	35.7	59.2	55.0	51.3	57.6
Planta 3	81.7	38.9	61.0	58.5	53.7	60.2

Estos resultados confirman una **alta correspondencia entre PSI y Wasserstein**, mientras que KS y Mann–Whitney muestran menor solapamiento con el resto. Esto sugiere que PSI y Wasserstein son más consistentes para detectar cambios continuos, mientras que KS y Mann–Whitney se comportan como métodos más específicos.

En general, **Golden–PSI** se posiciona como la combinación más sensible y consistente entre plantas, mientras que **Seasonal–Wasserstein** resulta más estable en series con estacionalidad marcada. Los valores coincidentes entre PSI y Wasserstein respaldan su uso conjunto para la detección de drift gradual,

4. Parámetros de drift para la generación de reportes

Esta sección documenta los parámetros que controlan la sensibilidad y estabilidad del cálculo de drift (ventana actual, re-muestreo y construcción de la referencia), tal como se utilizan al generar los reportes por planta. Indicamos el *rango sugerido*, el *valor actual* y el efecto práctico de aumentar o disminuir cada parámetro.

4.1 Parámetros globales utilizados

Los principales parámetros del flujo de drift controlan la ventana temporal analizada, el re-muestreo de datos y la forma en que se construye la referencia. A continuación se describen sus rangos típicos, el efecto de modificarlos y el valor utilizado actualmente en la generación de reportes.

- **CURRENT_WINDOW**: define el tramo de datos “actual” a comparar con la referencia. Aumentar este valor suaviza fluctuaciones y reduce falsos positivos, pero puede ocultar desviaciones lentas. Disminuirlo permite reaccionar más rápido a cambios recientes, aunque incrementa el ruido en el cálculo. Rango sugerido: 1D–7D. Valor actual: 3D.

- **RESAMPLE**: controla el intervalo de re-muestreo temporal aplicado a los datos.
Aumentar este valor reduce el ruido y mejora la estabilidad de la serie.
Disminuirlo mejora la resolución temporal y permite captar variaciones de corta duración.
Rango sugerido: 5–15min.
Valor actual: sin re-muestreo (**None**).
- **RESAMPLE_AGG**: define el método de agregación utilizado en el re-muestreo (**mean** o **median**).
Usar **median** atenúa picos y valores atípicos.
Usar **mean** preserva mejor la tendencia general.
Valor actual: **mean** (no aplica si **RESAMPLE=None**).
- **EXCLUDE_COLUMNS**: lista explícita de sensores problemáticos o no representativos que se omiten del análisis.
- **NUM_METHOD**: método estadístico utilizado para comparar distribuciones (KS, PSI, Wasserstein, Mann–Whitney).
Seleccionar KS o MWU prioriza detección de cambios bruscos o en forma.
Seleccionar PSI o Wasserstein mejora la detección de desplazamientos graduales o sostenidos.
Valor actual: **auto** (asignación automática según tipo de variable).
- **NUM_THRESHOLD**: umbral de decisión aplicado al método estadístico.
Aumentar este valor reduce la sensibilidad del sistema (menos alertas).
Disminuirlo incrementa la sensibilidad (mayor detección de cambios, riesgo de falsos positivos).
Valor actual: **None** (usa umbrales predeterminados del método).

4.2 Parámetros específicos por técnica de referencia

- **DECAY_HALF_LIFE_HOURS**: vida media de los pesos en la referencia exponencial.
Aumentar este valor hace el baseline más estable y con reacción más lenta.
Disminuirlo lo vuelve más sensible a los cambios recientes.
Rango sugerido: 24–168 h.
Valor actual: 168h (7 días).
- **DECAY_WEIGHT_MASS**: fracción acumulada de peso histórico usada como referencia.
Aumentar este valor incorpora más historia y mejora la robustez.
Disminuirlo prioriza los datos más recientes, aumentando la sensibilidad.
Rango sugerido: 0.90–0.99.
Valor actual: 0.95.

- **GOLDEN_WIN**: duración de cada ventana histórica evaluada en la estrategia “Golden”.
Aumentar este valor suaviza el ruido y mejora la estabilidad del baseline.
Disminuirlo hace la referencia más sensible a fluctuaciones recientes.
Rango sugerido: 15–60 min.
Valor actual: 30min.
- **GOLDEN_STEP**: desplazamiento entre ventanas históricas consecutivas.
Aumentar este valor reduce el costo computacional del barrido histórico.
Disminuirlo mejora la resolución temporal de la exploración.
Rango sugerido: 5–15 min.
Valor actual: 10min.
- **GOLDEN_K**: número de ventanas más estables concatenadas para formar la referencia.
Aumentar este valor produce un baseline más robusto y estable.
Disminuirlo incrementa la sensibilidad ante cambios operativos recientes.
Rango sugerido: 20–60.
Valor actual: 40.
- **SEASONAL_WEEKS_BACK**: semanas hacia atrás usadas para construir la referencia estacional (mismo día/hora).
Aumentar este valor permite capturar mejor la estacionalidad de largo plazo.
Disminuirlo mejora la adaptación frente a cambios recientes en operación.
Rango sugerido: 8–16 semanas.
Valor actual: 12 **semanas**.

4.3 Umbrales por métodos estadísticos

Los umbrales definen los niveles de severidad a partir de los cuales se considera que una variable presenta drift significativo. A continuación se resumen los valores recomendados para cada método estadístico, junto con su interpretación práctica y sugerencias de calibración.

- **PSI**: mide la divergencia entre histogramas de referencia y actual.
Valores cercanos a 0 indican estabilidad; mayores implican cambios en la distribución.
Umbrales sugeridos: 0.2 para drift moderado, 0.3 para alto.
En operación continua, se recomienda un umbral dinámico basado en el percentil p90–p95 del PSI histórico de cada columna, para evitar sobre-sensibilidad en señales muy variables.
- **KS (Kolmogorov-Smirnov)**: compara las distribuciones acumuladas de ambas ventanas.
Sensible a diferencias en forma o posición.
Umbrales típicos: 0.10–0.20.
Tiende a aumentar con el tamaño de muestra, por lo que se recomienda usarlo como “segunda opinión” para confirmar cambios bruscos detectados por otros métodos.

- **WASSERSTEIN**: evalúa la distancia promedio entre cuantiles de ambas distribuciones. Detecta desplazamientos graduales en la media o dispersión. Umbral relativo sugerido: $\approx 0,5 \sigma_{\text{ref}}$ (conservador) a $1,0 \sigma_{\text{ref}}$ (estricto), donde σ_{ref} es la desviación estándar de la referencia. Recomendado para series continuas o métricas de proceso con variaciones lentas.
- **MANN-Whitney (U normalizado)**: prueba no paramétrica sensible a *shifts* de localización. Útil para validar cambios de mediana o desplazamientos sistemáticos. Umbral indicativo: valores de $U > 0,55$ o $U < 0,45$ según la normalización adoptada. Conviene interpretarlo en conjunto con PSI o KS para una visión más completa.

Estrategia recomendada: combinar PSI + Wasserstein como par principal (alta consistencia para drift gradual) y utilizar KS / Mann–Whitney como métodos de validación para confirmar cambios abruptos o de forma.

5. Conclusiones y trabajo futuro

Conclusiones

- Ambos métodos de detección de outliers son útiles, pero el más sencillo de optimizar y el de mejores resultados es el basado en la diferenciación.
- Los métodos estadísticos PSI y Wasserstein presentan alta consistencia para detectar drift gradual entre plantas, mientras que KS y Mann–Whitney actúan como validadores útiles de cambios bruscos o de forma.
- La estrategia Golden ofrece un baseline robusto ante ruido y picos aislados, Seasonal captura bien ciclos horarios/semanales, Decay responde mejor a cambios recientes.
- La calibración operativa se beneficia de umbrales dinámicos por columna (p90–p95 histórico) y del escalado relativo en Wasserstein (σ_{ref}).

Trabajo futuro

- Automatizar umbrales dinámicos por columna y estrategia, con revisión periódica y control de tasa de alertas objetivo.
- Cobertura y calidad de ventana: integrar indicadores mínimos de tamaño muestral y cobertura para marcar resultados no concluyentes.
- Reporte unificado por planta: consolidar tablas “Top- k variables” con mayor score + breve hipótesis operativa.

6. Citas

Takeuchi, J.-I., & Yamanishi, K. (2006). *A unifying framework for detecting outliers and change points from non-stationary time series data*. In *Proceedings of the 2006 SIAM International Conference on Data Mining* (pp. 560–564). Association for Computing Machinery. <https://doi.org/10.1145/775047.775148>

Evidently AI. (2023). *Evidently: Open-source tools for data drift and model monitoring*. Consultado en: <https://www.evidentlyai.com/>