



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
INSTITUTO DE INGENIERÍA MATEMÁTICA Y COMPUTACIONAL

Sistema de Monitoreo de Calidad de Datos mediante Detección de Outliers y Drift

Franco Chiappe

Vicente Garay

Ziyu Guo

Proyecto de Grado para optar al grado de Licenciado en
Ingeniería en Ciencia de Datos

Santiago de Chile, 2025



Sistema de Monitoreo de Calidad de Datos mediante Detección de Outliers y Drift

Franco Chiappe
Vicente Garay
Ziyu Guo

Trabajo de Grado presentado a la comisión evaluadora:

Profesor del Curso:

Luis Cristóbal Rojas

Equipo Docente:

Jorge Salas

Joaquín Cabello

Profesor Asignado:

José Verschae

Representantes Ainwater:

Yaniela Fernández

Constanza Córdova

Santiago de Chile, 2025

DEDICATORIA

A nuestras familias, por enseñarnos a perseverar.

A Paz y Luna, por su amor, comprensión y apoyo constante.

A Pelusa y Carusso, quienes estuvieron presentes en cada jornada de trabajo.

AGRADECIMIENTOS

Agradecemos especialmente a Yaniela Fernández, de Ainwater, por su constante disposición, acompañamiento técnico y participación activa en las reuniones semanales, las cuales fueron fundamentales para orientar el desarrollo de este proyecto. Extendemos también nuestro agradecimiento a Constanza Córdova por su apoyo en fases iniciales del trabajo.

Asimismo, reconocemos el aporte del equipo docente del curso, cuya retroalimentación fue clave en las distintas evaluaciones del semestre. En particular, agradecemos a Joaquín Cabello por su guía detallada y su constante disposición para aclarar dudas y revisar nuestro progreso.

ABSTRACT

El monitoreo automático de la calidad de datos es esencial en sistemas que dependen de mediciones provenientes de sensores industriales. En Ainwater, estos datos presentan ruido, lagunas, valores atípicos y cambios en su distribución, afectando la confiabilidad operacional y el desempeño de modelos analíticos.

Este proyecto desarrolla un sistema compuesto por dos módulos independientes: uno para la detección de outliers y otro para la detección de drift en series de tiempo univariadas. El módulo de outliers combina un modelo basado en series de tiempo con un enfoque de diferenciación estadística que permite identificar anomalías puntuales y agrupadas. El módulo de drift compara ventanas temporales mediante PSI, KS y Wasserstein, integrando estrategias de referencia y métricas temporales que permiten evaluar tanto la calidad como la oportunidad de detección.

La solución fue validada con datos reales y sintéticos, demostrando un desempeño consistente y una estructura modular apta para su integración en la plataforma Poseidón.

Índice

Dedicatoria	I
Agradecimientos	II
ABSTRACT	III
1 INTRODUCCIÓN Y CONTEXTO DEL PROBLEMA	1
2 OBJETIVOS DEL PROYECTO	2
2.1 Objetivo General	2
2.2 Objetivos Específicos de Ciencia de Datos	2
2.3 Objetivos de Negocio	2
3 DESCRIPCIÓN DE LOS DATOS DE ENTRADA	3
3.1 Fuentes de Datos	3
3.2 Variables	3
3.3 Problemas Observados en los Datos	4
3.3.1 Discontinuidades y Lagunas de Datos	4
3.3.2 Variables con Varianza Nula	5
3.3.3 Variables con Comportamiento ON/OFF	5
3.4 Datos Sintéticos	5
4 DESCRIPCIÓN Y JUSTIFICACIÓN DE LA SOLUCIÓN	6
4.1 Descripción General del Sistema	6
4.2 Módulo de Detección de Outliers	6
4.2.1 Modelo Basado en Series de Tiempo	6
Formulación Matemática del Outlier Score	6
4.2.2 Modelo Basado en Diferenciación Estadística	7
4.3 Módulo de Detección de Drift	8
4.3.1 Ventanas de evaluación	8
4.3.2 Estrategias de referencia	8
Decay	9
Seasonal	9
Golden	9
4.3.3 Métodos estadísticos de comparación	9
PSI (Population Stability Index)	9
KS (Kolmogorov–Smirnov)	9
Wasserstein Distance	10
4.3.4 Ajustes según tipo de variable	10
Plateau Vars	10
Cyclical Vars	10
4.3.5 Criterio de Detección de Drift	10
4.4 Integración y Flujo General del Sistema	11

4.4.1	Flujo Drift Pipeline	11
4.4.2	Flujo del Pipeline de Detección de Outliers	11
5	DESCRIPCIÓN DE LOS RESULTADOS Y ENTREGABLES ESPERADOS	12
5.1	Entregables del Proyecto	12
5.1.1	Hito 1: Diagnóstico de datos y entendimiento del dominio	12
5.1.2	Hito 2: Propuesta de solución y primeras implementaciones	12
5.1.3	Pipeline Outliers	12
5.1.4	Pipeline Drift	12
5.2	Resultados Esperados	12
5.2.1	Estructura esperada de resultados	13
5.2.2	Criterios de desempeño esperados	13
6	METODOLOGÍA	14
6.1	Metodología de Desarrollo	14
6.2	Validación	15
6.2.1	Validación Detección de Outliers	15
6.2.2	Validación Detección de Drift	15
6.2.3	Validación con la Contraparte	15
7	RESULTADOS OBTENIDOS	16
7.1	Métricas de Evaluación	16
7.2	Resultados del Módulo de Outliers	16
7.3	Resultados del Módulo de Drift	17
8	CONCLUSIONES	20
8.1	Conclusiones Detección de Outliers	20
8.2	Conclusiones Detección de Drift	20
8.3	Conclusiones Generales	21
9	LIMITACIONES	22
9.1	Limitación de la Detección de Outliers	22
9.2	Limitación de la Detección de Drift	22
	Bibliografía	23
10	ANEXOS	24
10.1	Fundamentación Teórica de la Métrica Mixta para Drift	24
10.2	Visualización Nubes de Outliers	25

1 INTRODUCCIÓN Y CONTEXTO DEL PROBLEMA

El monitoreo continuo de la calidad de datos se ha convertido en un componente fundamental para organizaciones que dependen de información operacional para la toma de decisiones. En particular, Ainwater, empresa dedicada a la digitalización y optimización de procesos en plantas de tratamiento de agua ha desarrollado durante los últimos años la plataforma Poseidón, un sistema encargado de centralizar, visualizar y analizar datos provenientes de sensores industriales. Sin embargo, la creciente incorporación de plantas, variables y flujos operacionales ha evidenciado la necesidad de contar con herramientas automáticas capaces de identificar de manera temprana comportamientos anómalos en las series de tiempo, tanto a nivel puntual como estructural.

En este contexto, el proyecto aborda dos tipos de anomalías que afectan directamente la confiabilidad de los datos. Por un lado, los outliers, entendidos como observaciones puntuales o transitorias que se alejan significativamente del comportamiento esperado de una variable y que suelen estar asociadas a fallas momentáneas, ruido, errores de transmisión u operaciones inusuales. Por otro lado, el drift, definido como un cambio sostenido o progresivo en la distribución estadística de una variable, ya sea abrupto o gradual, que puede reflejar degradación de sensores, alteraciones en las condiciones de proceso o modificaciones reales en el comportamiento del sistema. Detectar ambos fenómenos resulta clave para asegurar que los análisis posteriores desde dashboards operacionales hasta algoritmos predictivos se basen en datos confiables y representativos.

En este trabajo se desarrolló un sistema compuesto por dos módulos complementarios: uno dedicado a la detección de outliers y otro orientado a la detección de drift en series de tiempo operacionales. Ambos forman parte del proceso de monitoreo de calidad de datos requerido por Ainwater y sirven como base para garantizar que la información utilizada en análisis posteriores sea coherente y confiable. A lo largo del informe se presentan las motivaciones del proyecto, los datos utilizados, el diseño de cada módulo, la metodología aplicada para su validación y los principales resultados obtenidos, permitiendo comprender de manera integral el funcionamiento y alcance de la solución propuesta.

2 OBJETIVOS DEL PROYECTO

2.1 Objetivo General

Diseñar e implementar un sistema integral de monitoreo de calidad de datos para series de tiempo, que permita detectar de manera automática outliers y drift en las variables registradas por la plataforma Poseidón. El sistema debe contemplar el tratamiento y selección adecuada de datos provenientes de sensores los cuales pueden presentar inconsistencias, ruido o registros incompletos de modo que las señales utilizadas en los análisis sean representativas y útiles. Además, el sistema debe ser modular, reproducible y consistente con las necesidades de operación de Ainwater, facilitando la identificación temprana de anomalías y contribuyendo a mejorar la confiabilidad de los procesos y análisis posteriores.

2.2 Objetivos Específicos de Ciencia de Datos

- Establecer un proceso sistemático de tratamiento y selección de datos útiles, considerando que los registros provenientes de sensores pueden contener ruido, valores faltantes, duplicados, interrupciones u otras inconsistencias que afecten la detección de anomalías.
- Implementar un modelo de detección de outliers, que se adapte a la variabilidad de los datos, minimizando la tasa de falsos positivos sin intervención humana.
- Implementar un módulo de detección de drift que permita comparar distribuciones de variables mediante ventanas temporales y métodos estadísticos, evaluando tanto cambios abruptos como graduales en la distribución subyacente.
- Diseñar un proceso de validación cuantitativa basado en episodios etiquetados, métricas de desempeño y análisis de retraso en la detección, permitiendo comparar métodos y configuraciones.
- Estructurar los pipelines de forma modular, escalable y configurable, asegurando su ejecución independiente, su parametrización mediante archivos JSON y su capacidad de adaptarse a múltiples plantas y variables.

2.3 Objetivos de Negocio

- Mejorar la confiabilidad operativa de la plataforma Poseidón mediante la detección temprana de valores atípicos y cambios inesperados en datos de sensores industriales.
- Reducir el impacto operacional de datos defectuosos o no representativos, permitiendo que los equipos técnicos identifiquen rápidamente sensores degradados o inconsistencias en la medición.
- Aumentar la calidad de los datos utilizados en dashboards, reportabilidad y modelos predictivos, asegurando entradas consistentes y representativas.
- Entregar a Ainwater herramientas claras, automatizables y fácilmente integrables en sus flujos actuales, minimizando costos de implementación y operación.

3 DESCRIPCIÓN DE LOS DATOS DE ENTRADA

3.1 Fuentes de Datos

El conjunto de datos utilizado en este proyecto fue proporcionado por Ainwater y corresponde a series de tiempo donde cada planta genera mediciones minuto a minuto de manera continua; no obstante, la frecuencia efectiva puede presentar ligeras variaciones debido a lagunas o interrupciones, aspecto que se detalla más adelante en esta sección. Los datos se entregaron en tres archivos .csv, uno por planta. Cada archivo contiene las mediciones registradas por sensores independientes, por lo que las estructuras de columnas difieren entre plantas tanto en número de variables como en su naturaleza.

Estas series provienen de tres plantas de tratamiento de agua con características operacionales y tamaños muy distintos:

- **Planta Urbana (Planta 1):** Planta de tratamiento de aguas servidas correspondiente a una zona pública. ~83 000 registros (aprox. 3 meses).
- **Planta Industrial (Planta 2):** Instalación dedicada al tratamiento de residuos industriales líquidos provenientes de una empresa láctea. ~440 000 registros (aprox. 1 año).
- **Planta Rural (Planta 3):** Instalación de menor escala ubicada en una zona no urbana. ~22 500 registros (aprox. 15 días).

En conjunto, el tamaño total no supera los 60 MB, por lo que no fue necesario utilizar infraestructura computacional adicional para su procesamiento.

3.2 Variables

Cada planta cuenta con un conjunto distinto de variables, reflejando diferencias en sus procesos y en el nivel de instrumentación. Todas las mediciones corresponden a series de tiempo univariadas asociadas a un *timestamp* común. A continuación se resumen las características principales.

Planta 1 (Planta Urbana)

El archivo contiene 16 columnas: una columna temporal y 15 variables numéricas asociadas a caudales, niveles de estanques y mediciones físico-químicas como pH y conductividad. La disponibilidad es alta en la mayoría de las variables (más de 82 000 valores no nulos), salvo en *pH Ecualizador 2*. Se identificaron además variables con varianza nula, como *Temperatura DAF*.

Planta 2 (Planta Industrial)

Este archivo incluye 14 columnas: una columna temporal y 13 variables continuas relacionadas con flujos, niveles y oxígeno disuelto en distintos reactores. La disponibilidad es heterogénea: algunas variables superan los 420 000 registros válidos, mientras que otras presentan una proporción considerable de datos faltantes (por ejemplo, las mediciones de OD).

Planta 3 (Planta Rural)

La planta rural contiene 6 columnas: una columna temporal, tres variables continuas (*Nivel pozo*, *Presión pozo*, *Energía Total Activa*) y dos variables binarias (*Falla Pozo* y *Falla Asimetría*). Estas últimas muestran un comportamiento ON/OFF característico.

Resumen

En conjunto, las plantas presentan:

- Variables continuas y binarias con escalas y naturalezas distintas.
- Diferencias importantes en número de columnas y disponibilidad de datos.
- Valores faltantes en varias mediciones, especialmente en OD y pH específicos.

Estas características motivan la necesidad de un tratamiento previo y selección cuidadosa antes de aplicar los módulos de detección de outliers y drift.

3.3 Problemas Observados en los Datos

Si bien los datos eran adecuados para abordar los objetivos del proyecto, presentaron ciertos problemas típicos de sistemas basados en sensores industriales.

3.3.1 Discontinuidades y Lagunas de Datos

Se identificaron interrupciones en la recepción de datos tanto de corta como de larga duración. Las lagunas pequeñas (1–5 minutos) se asocian principalmente a fallas intermitentes de comunicación, mientras que también se observaron detenciones prolongadas, como un evento de aproximadamente 17 días registrado en la Planta Urbana.



Figura 3.1: Ejemplo de lagunas en la variable *OD Reactor 1* (Planta 2)

3.3.2 Variables con Varianza Nula

Algunas variables permanecieron constantes durante todo el periodo de observación, como *Temperatura DAF* en la Planta Urbana. Al no aportar información relevante, estas columnas fueron descartadas del análisis.




Figura 3.2: Ejemplo de varianza nula *Temperatura DAF* (Planta 1)

3.3.3 Variables con Comportamiento ON/OFF

Estas señales son de naturaleza discreta y binaria, representando estados de operación (encendido/apagado) de equipos como bombas, ventiladores o válvulas. Se caracterizan por cambios abruptos entre valores fijos (típicamente 0 y 1), y no entregan información continua sobre el comportamiento del sistema, por lo que no son compatibles con métodos estadísticos de detección de drift.

3.4 Datos Sintéticos

Para validar los métodos desarrollados bajo escenarios controlados, se complementaron los datos reales con conjuntos sintéticos específicos para cada módulo. En el caso de outliers, el testeo se realizó utilizando directamente los datos de las plantas, empleando una herramienta proporcionada por Ainwater que permite etiquetar valores atípicos con distinta magnitud y frecuencia según criterios definidos. Esto permitió generar escenarios de anomalías de manera consistente con el comportamiento real de los sensores.

Por otro lado, el análisis de drift se evaluó mediante series totalmente sintéticas, construidas sin relación directa con las plantas. Estas series fueron diseñadas para forzar cambios graduales o abruptos en la distribución, etiquetando manualmente los episodios con el fin de medir de manera precisa el desempeño del módulo de detección.




Figura 3.3: Ejemplo variable datos sintéticos *var_6* (synthetic_plant)

Los datos sintéticos permitieron cuantificar precisión, recall, F1-score y retraso en la detección bajo configuraciones replicables, facilitando la comparación entre estrategias y umbrales utilizados en el desarrollo del sistema.

4 DESCRIPCIÓN Y JUSTIFICACIÓN DE LA SOLUCIÓN

4.1 Descripción General del Sistema

La solución desarrollada consiste en dos pipelines completamente independientes, diseñados para abordar de manera diferenciada los dos tipos de anomalías estudiadas en este proyecto: valores atípicos (outliers) y cambios en la distribución estadística de una variable a lo largo del tiempo (drift). Cada pipeline posee su propia arquitectura, parámetros, criterios de evaluación y archivos de salida, permitiendo que ambos módulos operen sin dependencias entre sí.

El pipeline de detección de outliers se centra en identificar valores puntuales anómalos o errores de medición en las series de tiempo provenientes de sensores industriales. Dado que cualquier variable puede presentar lecturas irregulares debido a ruido, fallas o condiciones operacionales transitorias, este pipeline se aplica de manera transversal sobre todas las variables disponibles en cada planta.

Por otra parte, el pipeline de detección de drift está orientado a identificar cambios estructurales o sostenidos en la distribución de una variable, lo cual es especialmente relevante en aquellas señales que alimentan modelos predictivos o procesos analíticos sensibles a variaciones temporales. En consecuencia, este pipeline se ejecuta únicamente sobre un subconjunto de variables seleccionadas por su relevancia en los modelos utilizados por Ainwater.

Si bien ambos pipelines operan con entradas similares (archivos .csv por planta), sus configuraciones, métodos y criterios de decisión son distintos. Cada uno genera archivos de resultados independientes que incluyen etiquetas de anomalías por variable y facilitan su integración futura en sistemas de monitoreo automatizado como la plataforma Poseidón.

4.2 Módulo de Detección de Outliers

Esta solución se fundamenta en la necesidad de identificar valores atípicos y errores de medición en los sensores. Para afrontar este problema se implementaron dos metodologías distintas.

4.2.1 Modelo Basado en Series de Tiempo

Este enfoque de detección de outliers se basa en [Takeuchi and Yamanishi, 2006], el cual fue diseñado para operar en datos no estacionarios. La premisa del algoritmo es modelar la dependencia temporal de la variable y analizar los residuos del modelo.

Este método permite utilizar diversos modelos predictivos (ARMA, GARCH, IGARCH, etc.). Para esta implementación se utilizaron tres modelos de serie de tiempo: AR, MA y ARMA, privilegiando la eficacia computacional y evitando problemas de invertibilidad.

Formulación Matemática del Outlier Score

El algoritmo define si un dato es outlier según su *outlier_score*. Para calcular este score se asume que los residuos de la predicción se comportan como un ruido blanco gaussiano. Las desviaciones significativas se marcan como anomalía.

Sea x_t el valor observado en el tiempo t y $\hat{x}_t$ la predicción generada por el modelo de serie de tiempo. Se define el residuo r_t como:

$$r_t = x_t - \hat{x}_t$$

El modelo no asume una varianza constante, sino que se adapta utilizando s_t^2 como la varianza dinámica, que se calcula según:

$$s_t^2 = (1 - \alpha)s_{t-1}^2 + \alpha r_t^2$$

donde $\alpha \in [0, 1]$ es el factor de suavizado.

Como se mencionó anteriormente, el modelo asume que los residuos se comportan como un ruido blanco gaussiano, es decir $r_t \sim \mathcal{N}(0, s_t^2)$. Para calcular el *outlier_score* se utiliza la neg log-verosimilitud:

$$score(x_t) = -\log p_{t-1}(x_t) \approx \frac{1}{2} \left(\log(2\pi s_t^2) + \frac{r_t^2}{s_t^2} \right)$$

Un puntaje alto indica que el valor tiene baja probabilidad de ocurrencia. Un punto se marca como outlier si el *outlier_score* supera el cuantil indicado en los parámetros del modelo.

Por otra parte, el paper ofrece una librería en Python que incluye *changepoint*. Este método utiliza un modelo AR para detectar puntos en donde hay un cambio de distribución. Recibe el coeficiente AR a utilizar, un factor de suavizado y el cuantil que debe superar el *change_score* para ser marcado como cambio.

Ambos modelos se utilizan de manera simultánea, de modo que si un punto es detectado como outlier y como cambio en la distribución, se marca solo como cambio, reduciendo falsos positivos.

4.2.2 Modelo Basado en Diferenciación Estadística

Este método se inspira en los fundamentos de análisis de series de tiempo explicados en [Palma, 2016], donde se utiliza la diferenciación en las series para afrontar el problema de la no estacionaridad de los datos.

Adaptando este concepto al contexto de detección de anomalías, se desarrolló un modelo que utiliza la diferenciación entre vecinos inmediatos, utilizando la siguiente fórmula:

$$x_t = \min(|y_t - y_{t-1}|, |y_t - y_{t+1}|)$$

Un dato se detecta como outlier si y solo si cumple con alguna de las siguientes condiciones:

$$\text{IsOutlier}(y_t) \iff (x_t \geq \lambda \cdot \sigma_{diff}) \vee (|y_t - y_{t-1}| \geq k) \quad (4.1)$$

Es decir, se marca como outlier si la diferencia centrada es mayor a la desviación estándar histórica multiplicada por un factor λ , o si la diferencia con el dato anterior es superior a un umbral k . Este k se puede calcular como la diferencia entre el cuantil 25 y 99 de la serie, y se utiliza para detectar cambios muy abruptos que no son capturados por la diferencia centrada.

Los parámetros utilizados son:

- σ_{diff} : desviación estándar histórica de las diferencias centradas, es decir, de los x_t .

- λ : factor que determina cuántas desviaciones estándar debe alejarse x_t para ser detectado como outlier.
- k : umbral de diferencia utilizado para detectar cambios muy abruptos.

Otra ventaja de este modelo, es el cálculo de σ_{diff} , ya que se calcula una sola vez con los datos pasados. Y después se puede ir actualizando al recibir nuevos datos, con la fórmula:

$$\sigma_t^2 = \frac{t-1}{t} \cdot \sigma_{t-1}^2 + \frac{1}{t} \cdot x_t^2$$

Con t la cantidad de datos actual.

También se puede cambiar a la siguiente fórmula:

$$\sigma_t^2 = (1 - \alpha) \cdot \sigma_{t-1}^2 + \alpha \cdot x_t^2$$

Con α un factor de suavizado, ya que $\frac{1}{t}$ con un volumen grande de datos, es casi 0. Por lo que utilizando un α pequeño, por ejemplo 0.01, se da más peso a los nuevos datos. Adaptándose a cambios de volatilidad.

4.3 Módulo de Detección de Drift

El módulo de detección de drift tiene como objetivo identificar cambios significativos y sostenidos en la distribución estadística de una variable respecto a su comportamiento histórico. A diferencia de los outliers, que corresponden a anomalías puntuales, el drift refleja variaciones estructurales en la forma, ubicación o dispersión de la distribución y puede afectar directamente el desempeño de modelos predictivos y la interpretación operacional de los datos.

Este módulo se aplica únicamente sobre un subconjunto de variables seleccionadas por AINwater, en particular aquellas cuya estabilidad temporal resulta crítica para modelos analíticos o decisiones de operación.

4.3.1 Ventanas de evaluación

Para evaluar el comportamiento reciente de una variable, el sistema construye una ventana actual que resume los valores observados en un intervalo temporal reciente. El objetivo del detector es comparar esta ventana con una referencia histórica formada exclusivamente con datos anteriores al instante de evaluación.

El drift se identifica al medir la discrepancia estadística entre ambas ventanas. La calidad del detector depende, por lo tanto, de cómo se construye dicha referencia histórica. En este proyecto, la referencia se genera mediante tres estrategias complementarias.

4.3.2 Estrategias de referencia

Sea $\{x_t\}_{t=1}^T$ la serie temporal de una variable. El sistema implementa tres formas de construir la referencia histórica R_t .

Decay

A cada observación histórica con timestamp $t_i < t$ se asigna un peso exponencial decreciente

$$w_i = \exp\left(-\frac{t - t_i}{\tau}\right),$$

donde τ depende del parámetro `half_life_hours`. Se ordenan las observaciones por recencia y se selecciona el prefijo cuya masa acumulada supera `target_mass`. Este subconjunto constituye la referencia R_t y privilegia observaciones recientes.

Seasonal (ciclos completos)

Sea $C = \text{cycle_hours}$ la duración de un ciclo (por ejemplo, 24 horas) y $K = \text{cycles_back}$ el número de ciclos considerados. La referencia se construye concatenando segmentos históricos definidos por

$$I_k = (t - kC, t - (k - 1)C], \quad k = 1, \dots, K,$$

lo que permite comparar la ventana actual con ciclos históricos homologables.

Golden (ventanas estables)

El historial se recorre mediante ventanas móviles de tamaño `win` y paso `step`. Para cada ventana $[u, u + \Delta)$ se calcula un indicador robusto de estabilidad:

$$\text{RSD}_u = \text{mediana}\left(\frac{\text{IQR}}{|\text{mediana}| + \varepsilon}\right).$$

Se seleccionan las k ventanas más estables y se concatenan para formar R_t . Esta estrategia representa períodos históricos de operación normal.

4.3.3 Métodos estadísticos de comparación

Definidas la ventana actual $W_t^{(\text{cur})}$ y la referencia histórica R_t , el sistema calcula un *drift score* mediante uno de los siguientes métodos estadísticos:

PSI (Population Stability Index)

Comparando distribuciones discretizadas en intervalos comunes, si p_i y q_i son las proporciones de referencia y ventana actual respectivamente, entonces

$$\text{PSI} = \sum_{i=1}^m (q_i - p_i) \ln\left(\frac{q_i}{p_i}\right).$$

KS (Kolmogorov–Smirnov)

Mide la máxima discrepancia entre las funciones de distribución acumulada empíricas:

$$D = \sup_x |F_{\text{ref}}(x) - F_{\text{cur}}(x)|.$$

Wasserstein Distance

$$W_1 = \int_0^1 |F_{\text{ref}}^{-1}(u) - F_{\text{cur}}^{-1}(u)| du.$$

La función `score_numeric_series` selecciona internamente la métrica solicitada y devuelve el *drift score* numérico.

4.3.4 Ajustes según tipo de variable

Algunas variables presentan comportamientos particulares que requieren tratamientos específicos antes de aplicar los métodos de detección de drift. En ciertos casos, las señales pasan largos periodos en valores extremos que no representan operación real, mientras que otras exhiben estacionalidad marcada asociada a ciclos diarios u horarios. Para asegurar que las comparaciones entre ventanas reflejen únicamente los periodos en que la variable está efectivamente en operación y que la estacionalidad no genere falsos positivos se aplican los siguientes ajustes adicionales por tipo de comportamiento.

Plateau Vars

Algunas variables continuas presentan largos periodos en los que su valor se mantiene cercano al mínimo o máximo operativo sin cambios relevantes. Estas variables no son binarias, pero muestran mesetas prolongadas que no reflejan operación real del sistema. Un ejemplo típico es el nivel de ciertos estanques que permanecen llenos durante horas sin registrar variación. Para estos casos, se aplica `mask_plateau_extreme`, que identifica y descarta dichos tramos según la tolerancia:

$$\varepsilon = \max(\text{abs_eps}, \text{rel_eps}(x_{\text{máx}} - x_{\text{mín}})),$$

y permite evaluar drift solo cuando la variable presenta actividad efectiva.

Cyclical Vars

Variables con estacionalidad fuerte (por ejemplo, ciclos diarios). Se fuerza automáticamente el uso de la estrategia `seasonal`, usando `cycle_hours` para definir la longitud del ciclo y comparar siempre ciclos completos homogéneos entre sí.

4.3.5 Criterio de Detección de Drift

Sea S_t el drift score correspondiente a la ventana actual y τ el umbral asignado a la variable. La detección se realiza mediante la siguiente regla de decisión:

$$\text{drift_flag}_t = I(S_t \geq \tau),$$

donde $I(\cdot)$ es la función indicadora.

El umbral τ puede definirse explícitamente para cada variable o calibrarse a partir del comportamiento histórico del método estadístico utilizado (por ejemplo, empleando percentiles de la distribución de S_t). La calibración detallada se describe en la sección de Metodología.

Finalmente, las etiquetas obtenidas por ventana se proyectan al nivel de cada timestamp, agrupando ventanas consecutivas en episodios contiguos de drift.

4.4 Integración y Flujo General del Sistema

El sistema completo está compuesto por dos pipelines completamente independientes. Un pipeline dedicado a la detección de outliers y un pipeline orientado exclusivamente a la detección de drift.

Cada uno posee su propio flujo de ejecución, parámetros, salida y criterios de configuración, de modo que pueden operar de manera autónoma y ser integrados por separado en la plataforma Poseidón u otros sistemas de monitoreo.

4.4.1 Flujo Drift Pipeline

- **Lectura del archivo de entrada** El sistema recibe un archivo .csv con las series temporales de las variables seleccionadas para análisis de drift.
- **Preprocesamiento y ajustes por variable** Se aplican los ajustes definidos para cada tipo de variable, ya sea eliminar mesetas extremas en variables *plateau*, forzar estacionalidad en variables *cyclical* y aplicación de filtros y parámetros de limpieza.
- **Construcción de ventanas y referencia** Se generan ventanas actuales y referencias históricas de acuerdo con la estrategia configurada: *decay*, *seasonal* o *golden*.
- **Cálculo del drift score.** Cada ventana se compara con su referencia mediante un método estadístico (PSI, KS o Wasserstein), obteniendo un puntaje.
- **Evaluación frente a umbrales** El puntaje se contrasta con un umbral fijo o calibrado para determinar la existencia de drift.
- **Reconstrucción temporal** Las etiquetas obtenidas por ventana se proyectan al nivel de cada *timestamp*, agrupando ventanas contiguas en episodios coherentes de drift.
- **Datos de salida** Con el modelo entrenado, se crea un dataset etiquetado por variable, y se guarda en .csv, en una carpeta llamada output.

4.4.2 Flujo del Pipeline de Detección de Outliers

- **Lectura del archivo de entrada.** El código recibe un archivo .csv, con series temporales, el flujo puede procesar todas las columnas o las columnas indicadas por el usuario
- **Selección de Hiperparámetros** Por defecto el código tiene sus hiperparámetros, pero se pueden ajustar como el usuario desee, además de seleccionar que método se utilizará, si el basado en series de tiempo o el modelo basado en la diferenciación.
- **Entrenamiento del Modelo** Se entrena el modelo para cada variable, según los hiperparámetros seleccionados.
- **Datos de salida** Con el modelo entrenado, se crea un dataset etiquetado por variable, y se guarda en .csv, en una carpeta llamada output.

5 DESCRIPCIÓN DE LOS RESULTADOS Y ENTREGABLES ESPERADOS

5.1 Entregables del Proyecto

Durante el desarrollo del proyecto se entregaron distintos productos organizados en dos grandes categorías: entregables de proceso, ligados a los hitos de avance definidos junto a la contraparte, y entregables funcionales, correspondientes a los pipelines desarrollados para la detección de anomalías.

5.1.1 Hito 1: Diagnóstico de datos y entendimiento del dominio

Centrado en el análisis preliminar de los datos entregados por Ainwater, consistió en un informe técnico donde se caracterizaron las variables y su disponibilidad por planta. Se identificaron problemas comunes como lagunas, varianza nula y señales ON/OFF numéricas, y se propusieron criterios de exclusión o tratamiento. Este hito permitió establecer un lenguaje común con la contraparte.

5.1.2 Hito 2: Propuesta de solución y primeras implementaciones

Correspondió a un informe donde se detalló la arquitectura propuesta del sistema y los primeros modelos implementados para detección de outliers y drift. Se justificaron decisiones de diseño, se incluyeron ejemplos de ejecución preliminar y se discutieron resultados exploratorios, lo que permitió validar el enfoque y recibir retroalimentación operativa.

5.1.3 Pipeline Outliers

Diseñado para identificar valores atípicos puntuales, el pipeline utiliza modelos basados en series de tiempo y diferenciación estadística. Permite ajustar hiperparámetros por variable y exporta resultados en formato tabular.

Repositorio: https://github.com/VicenteGarayR/Proyecto_Ainwater

5.1.4 Pipeline Drift

Orientado a identificar cambios sostenidos o estructurales en la distribución de variables, este pipeline permite definir estrategias de referencia, métricas estadísticas y umbrales personalizados.

Repositorio: <https://github.com/fchiapped/Drift-Ainwater>

5.2 Resultados Esperados

El sistema desarrollado apunta a ser una herramienta efectiva para monitoreo automático de la calidad de datos en series de tiempo provenientes de sensores industriales. Se espera que, al ejecutar los pipelines sobre datos operacionales, el sistema entregue archivos etiquetados que indiquen la presencia de anomalías, cumpliendo con criterios de precisión y generalización definidos.

5.2.1 Estructura esperada de resultados

Cada pipeline produce, como salida principal, un conjunto de archivos .csv que replican las series originales pero con una columna adicional por variable que indica la detección (o no) de una anomalía:

- En el caso de outliers, se espera una etiqueta binaria por timestamp que señale si el valor observado corresponde a un punto atípico, según los modelos implementados.
- En el caso de drift, se espera una etiqueta que identifique si un cierto periodo (ventana) presenta un cambio estadístico relevante en la distribución respecto a su referencia histórica, al igual que una etiqueta dato a dato de si es o no anomalía. Estas etiquetas se proyectan también a nivel de timestamp.

Estas salidas tienen como objetivo facilitar el análisis posterior, permitir trazabilidad y reducir la necesidad de validación manual de los datos operativos.

5.2.2 Criterios de desempeño esperados

Desde el inicio del proyecto, se estableció como criterio fundamental que el sistema:

- Detecte la mayor cantidad posible de anomalías reales (alta tasa de verdaderos positivos).
- Minimice la cantidad de falsos positivos, de modo que las alertas generadas sean confiables y no saturen a los usuarios.
- Ofrezca una estructura modular y ajustable, adaptable a distintas variables, sensores y plantas.

Estas metas guiarán la evaluación del sistema en etapas posteriores y permitirán contrastar los resultados reales con las proyecciones formuladas en esta sección.

6 METODOLOGÍA

6.1 Metodología de Desarrollo

Para la ejecución del proyecto se utilizó como guía la metodología CRISP-DM, cumpliendo con las siguientes etapas:

Comprensión del Negocio

Se realizaron reuniones semanales con el equipo de Ainwater para comprender el funcionamiento de las plantas, el tipo de datos registrados y las necesidades operacionales.

Comprensión de los Datos

Se efectuó un análisis exploratorio de las series de tiempo, incluyendo análisis de valores faltantes, estadísticas descriptivas, correlaciones, detección de outliers, patrones cíclicos y estacionalidad.

Estado del Arte

Durante la fase de investigación, se estudiaron distintos enfoques para la detección de anomalías y drift. Sin embargo, por la naturaleza del problema se descartaron varios métodos, como por ejemplo:

- En un principio, antes de recibir los datos de parte Ainwater, manejamos la opción de utilizar técnicas híbridas de aprendizaje automático para la detección de anomalías, como la combinación de PCA con Autoencoders, propuesta en [Baranwal et al., 2025]. Pero esta solución fue descartada, ya que es necesario tener columnas correlacionadas.
- Por otra parte, era una opción utilizar métodos basados en la densidad local, revisados en [Alghushairy et al., 2021]. Nos interesaba esta solución, ya que propone métodos de detección de outliers para datos en stream, y sin la necesidad de que sigan una distribución conocida. Pero este método fue descartado ya que tenía un costo computacional muy grande.
- También se revisaron enfoques recientes centrados específicamente en drift, como el propuesto por [Erhan et al., 2020], que plantea una arquitectura jerárquica que permite realizar detección eficiente en sensores IoT, diferenciando entre anomalías puntuales y cambios sostenidos en el tiempo. Este tipo de solución motivó el uso de comparaciones estadísticas entre ventanas en nuestros pipelines, priorizando eficiencia y adaptabilidad.

Preparación de los Datos

Se diseñaron y construyeron pipelines modulares en Python para procesar las series de sensores, estandarizar su formato, así preparandolas para aplicar los modelos univariados.

Modelado

Se seleccionaron e implementaron distintos enfoques para la detección de outliers y de drift. Para outliers se trabajó con modelos AR(2) y de diferenciación, mientras que para drift se utilizaron métodos basados en comparación de distribuciones (PSI, KS, Wasserstein).

Despliegue

Se construyeron dos pipelines: uno para detección de outliers y otro para detección de drift. Estos pipelines están diseñados para ser reutilizables, modulares y parametrizables.

6.2 Validación

6.2.1 Validación Detección de Outliers

La validación se realizó a partir de un conjunto de datos etiquetado manualmente, correspondiente a las tres plantas de tratamiento de Ainwater. El conjunto incluye eventos reales de operación anómala, lo cual permitió contrastar los modelos propuestos.

Se utilizaron las siguientes métricas:

- **Precision:** Mide cuántas de las anomalías detectadas realmente lo eran.
- **Recall:** Mide la capacidad del modelo para encontrar todos los casos relevantes.
- **F1:** Resume en una sola métrica el balance entre exactitud y cobertura.

6.2.2 Validación Detección de Drift

La validación de drift se realizó utilizando datos sintéticos generados específicamente para este fin. Se construyeron series con episodios que fueron etiquetados manualmente. Se calcularon las siguientes métricas:

- **F1:** Mide la calidad de detección general.
- **F1_time:** Versión modificada de F1 que penaliza retrasos en la detección, ponderando según la distancia temporal al inicio del episodio.
- **F1_mixto:** Combinación ponderada de ambas métricas (85 % F1 y 15 % F1_time), siguiendo la propuesta de [Almeida et al., 2021].

Estas métricas están detalladas en el Anexo *Validación Temporal*.

6.2.3 Validación con la Contraparte

Durante las reuniones semanales, se revisaron iterativamente los modelos con el equipo de Ainwater. Este trabajo colaborativo permitió:

- Ajustar parámetros y enfoques según el comportamiento observado.
- Definir categorías de variables específicas como Plateau Vars y Cyclical Vars, que emergieron tras análisis conjuntos con la contraparte.
- Priorizar la detección de eventos relevantes para operación de las plantas, reduciendo falsos positivos.

La evaluación cualitativa se complementó con la evaluación cuantitativa mencionada anteriormente, logrando un enfoque mixto centrado tanto en la precisión de los modelos como en su utilidad operativa.

7 RESULTADOS OBTENIDOS

7.1 Métricas de Evaluación

Para ambos módulos se utilizaron métricas estándar basadas en la comparación entre las etiquetas entregadas por el modelo y las etiquetas reales. A nivel general se definen:

- **True Positive (TP):** casos en que el modelo marca una anomalía y efectivamente existe.
- **False Positive (FP):** casos en que el modelo marca una anomalía o episodio que no existe.
- **False Negative (FN):** anomalías o episodios reales que el modelo no detecta.

A partir de estas cantidades, se calculan las métricas clásicas de desempeño:

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}, \quad F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}.$$

Estas métricas se utilizan tanto para evaluar la detección de outliers como para la detección de drift, con las adaptaciones necesarias según se trate de puntos individuales (outliers) o episodios (drift).

7.2 Resultados del Módulo de Outliers

Para esto seleccionaremos 4 variables de la planta 1 y 4 de la planta 2, tomando estas métricas a mano, es decir se ajustara el modelo y se revisara un gráfico por día viendo los aciertos y fallos.

Esto ya que ambos modelos se ven perjudicados cuando hay 2 o más outliers juntos, ya que solo detectan el primero.

Veamos como funcionaron los modelos, tomando datos del 06-01 hasta 08-09:

Cuadro 7.1: Resultados de Métricas TP, FP, FN para Modelos DIFF y Serie de tiempo

Modelo	Variable	TP	FP	FN
DIFF	pH coagulación entrada DAF	11 (+149)	8	2
	pH Clarificado DAF (Tk_80m3)	4	2	2
	pH salida a Parshall 02	1	1	0
	Flujo Salida de Lodo Sed. Sec. 3	27 (+245)	12	1
	Flujo Afluyente PTAR	1	0	1
	Flujo Cámara de contacto 2	1	0	1
Serie de tiempo	pH coagulación entrada DAF	10 (+59)	12	3 (+90)
	pH Clarificado DAF (Tk_80m3)	6	15	0
	pH salida a Parshall 02	0	20	1
	Flujo Salida de Lodo Sed. Sec. 3	15 (+94)	4	13 (+151)
	Flujo Afluyente PTAR	2	15	0
	Flujo Cámara de contacto 2	2	17	0

Los paréntesis indican 'nubes de outliers', es decir muchos outliers juntos, para el calculo de métricas solo se van a considerar como 1 un outlier por cada nube.

Ahora veamos las métricas obtenidas

Cuadro 7.2: Métricas de Evaluación (Precisión, Recall, F1) para Modelos DIFF y AR

Modelo	Variable	Precisión	Recall	F1-Score
DIFF	pH coagulación entrada DAF	0.579	0.846	0.688
	pH Clarificado DAF (Tk_80m3)	0.667	0.667	0.667
	pH salida a Parshall 02	0.500	1.000	0.667
	Flujo Salida de Lodo Sed. Sec. 3	0.692	0.964	0.806
	Flujo Afluyente PTAR	1.000	0.500	0.667
	Flujo Cámara de contacto 2	1.000	0.500	0.667
AR	pH coagulación entrada DAF	0.455	0.769	0.572
	pH Clarificado DAF (Tk_80m3)	0.286	1.000	0.445
	pH salida a Parshall 02	0.000	0.000	0.000
	Flujo Salida de Lodo Sed. Sec. 3	0.789	0.536	0.638
	Flujo Afluyente PTAR	0.118	1.000	0.211
	Flujo Cámara de contacto 2	0.105	1.000	0.190

Si se desea se pueden obtener menor falsos negativos, ajustando un λ menor, con el problema de obtener mayor falsos positivos, pero así detectando todos los outliers.

7.3 Resultados del Módulo de Drift

La evaluación del módulo de drift se realizó utilizando exclusivamente el conjunto de datos sintéticos generados para este proyecto. Las series incluyen episodios abruptos, graduales y mixtos en un periodo total de 20 días muestreados a nivel minuto. Todos los resultados reportados corresponden a ejecuciones controladas sobre dichas series.

Limitación de Métricas Clásicas y Uso de Métricas Temporales

Durante la evaluación se observó que, en presencia de episodios prolongados de drift, las métricas clásicas basadas en F1 alcanzan valores altos independientemente del retraso en la detección. Esto se debe a que, una vez detectado el episodio, el modelo continúa acumulando verdaderos positivos a lo largo de toda su duración.

Para medir el retraso temporal se incorporó la métrica $F1_time$, calculada mediante los pesos

$$w_i = 1 - \frac{d_i}{D_{\text{máx}}},$$

donde d_i es el retraso en la detección de la ventana i . La métrica final utilizada en los experimentos corresponde a la combinación lineal:

$$F1_{\text{mixto}} = 0,85 F1 + 0,15 F1_time.$$

Evaluación del Tamaño de Ventana

Se evaluaron cinco tamaños de ventana: 6H, 12H, 24H, 36H y 48H. Para cada combinación de método estadístico (KS, PSI y Wasserstein) y estrategia de referencia (Decay, Seasonal y Golden) se calculó el valor de $F1_{mixto}$.

La Figura 7.1 presenta el mapa de calor obtenido en esta evaluación.




Figura 7.1: Valores de $F1_{mixto}$ para distintos tamaños de ventana.

Resultados con Ventana de 36H

El tamaño de ventana de 36H presentó resultados estables y se utilizó para el resto de los experimentos. La Tabla 7.3 resume los valores completos de precisión, recall, F1 y $F1_{time}$ para cada método y estrategia.

Cuadro 7.3: Resultados completos (F1 y $F1_{time}$) con ventana de 36H.

Método	Estrategia	Precision	Recall	F1	Precision_time	Recall_time	F1_time
KS	Decay	1.0000	1.0000	1.0000	0.3705	0.9450	0.5323
KS	Seasonal	0.7419	1.0000	0.8519	0.2766	0.9450	0.4280
KS	Golden	1.0000	0.9565	0.9778	0.4870	0.9114	0.6344
PSI	Decay	1.0000	1.0000	1.0000	0.3688	0.9239	0.5271
PSI	Seasonal	0.7586	0.9565	0.8462	0.3046	0.9436	0.4606
PSI	Golden	1.0000	1.0000	1.0000	0.4992	0.9096	0.6446
Wasserstein	Decay	1.0000	1.0000	1.0000	0.3736	0.9360	0.5341
Wasserstein	Seasonal	0.7931	1.0000	0.8846	0.2964	0.9450	0.4513
Wasserstein	Golden	1.0000	1.0000	1.0000	0.4878	0.9110	0.6354

Métrica Final: $F1_{mixto}$

La Tabla 7.4 muestra los valores de $F1$, $F1_{time}$ y $F1_{mixto}$ obtenidos para cada combinación de método y estrategia usando la ventana de 36H.

Cuadro 7.4: Valores de $F1_{mixto}$ con ventana de 36H.

Métrica	Estrategia	F1	$F1_{time}$	$F1_{mixto}$
KS	Decay	1.0000	0.5323	0.9298
KS	Seasonal	0.8519	0.4280	0.7883
KS	Golden	0.9778	0.6344	0.9065
PSI	Decay	1.0000	0.5271	0.9291
PSI	Seasonal	0.8462	0.4606	0.8503
PSI	Golden	1.0000	0.6446	0.9447
Wasserstein	Decay	1.0000	0.5341	0.9301
Wasserstein	Seasonal	0.8846	0.4513	0.8620
Wasserstein	Golden	1.0000	0.6354	0.9533

8 CONCLUSIONES

8.1 Conclusiones Detección de Outliers

Después de desarrollar los dos modelos mencionados, y analizando sus respectivos resultados, concluimos lo siguiente:

- **Superioridad del Modelo de Diferenciación** Si bien inicialmente se podría creer que un modelo más complejo, como el basado en series de tiempo, capturaría mejor la varianza de los datos, el modelo de diferenciación estadística demostró ser más apto en el contexto de plantas de trata de aguas. Este modelo obtuvo mejores resultados, superando ampliamente en métricas como *Precisión* y *F1-Score* en las variables analizadas (ver Cuadro 7.2).
- **Detección de "Nube de Outliers"** Una de las mayores diferencias entre ambos modelos, fue la eficacia en detectar las "nubes de outliers". El modelo basado en series de tiempo, al basarse en la volatilidad dinámica, no detecta este tipo de anomalía. Por otra parte el modelo de diferenciación al operar con umbrales basados en σ_{diff} y la diferencia absoluta k . Logra detectar de manera efectiva estos eventos, obteniendo un mejor *Recall*, sin perjudicar la *precisión*.
- **Minimización de Falsos Positivos** Una de las preocupaciones de la contraparte es la cantidad de Falsos Positivos, ya que generan alertas innecesarias. Por lo mismo el modelo basado en diferenciación es efectivo en este contexto, a diferencia del modelo que utiliza series de tiempo, el cual funciona con cuantiles, el algoritmo de diferenciación utiliza umbrales basados en el pasado, generando menos alertas.
- **Eficacia computacional** Por último, el modelo de diferenciación es más eficaz computacionalmente, ya que como se mencionó anteriormente, el σ_{diff} se puede ir actualizando solo con el dato nuevo. Es decir actualizar el σ_{diff} es $O(1)$

8.2 Conclusiones Detección de Drift

A partir de los experimentos realizados con el dataset sintético y de los valores obtenidos para las distintas combinaciones de métodos estadísticos, estrategias de referencia y tamaños de ventana, se concluye lo siguiente:

- **Robustez general de los métodos estadísticos** Los tres métodos evaluados (KS, PSI y Wasserstein) alcanzaron valores altos de *F1* en todos los escenarios, confirmando su capacidad para capturar diferencias sostenidas en la distribución.
- **Estabilidad del método Wasserstein** El método basado en la distancia de Wasserstein mostró un desempeño especialmente estable, con valores máximos de *F1* y altos valores de *F1_mixto* en todas las estrategias evaluadas.
- **Estrategia Golden como la más consistente** Al evaluar el desempeño mediante *F1_mixto*, la estrategia *Golden* obtuvo puntajes altos y estables en la mayoría de los métodos, destacando especialmente en PSI y Wasserstein.

- **Comportamiento del componente temporal** La métrica $F1_{time}$ permitió distinguir entre detecciones tardías y oportunas. Las estrategias *Decay* y *Golden* obtuvieron valores temporales consistentemente superiores a la estrategia *Seasonal*.
- **Preferencia por ventanas** Los tamaños de ventana entre 12H y 36H presentaron valores superiores de $F1_{mixto}$ frente a ventanas más cortas o más largas. La ventana de 36H mostró el comportamiento más estable y se utilizó para los resultados finales.
- **Diferencias entre $F1$, $F1_{time}$ y $F1_{mixto}$** . Los experimentos mostraron que la métrica clásica $F1$ tiende a sobreestimar el desempeño del detector en episodios prolongados, ya que no penaliza retrasos en la detección. Por el contrario, $F1_{time}$ permite capturar esta diferencia al reflejar explícitamente la prontitud de la detección. La métrica combinada $F1_{mixto}$ integró ambas dimensiones de forma equilibrada y mostró ser la más informativa para comparar configuraciones, motivo por el cual se adopta como criterio principal de evaluación del módulo de drift.

8.3 Conclusiones Generales

El desarrollo de este proyecto permitió diseñar, implementar y validar un sistema integral de monitoreo de calidad de datos capaz de detectar de manera automática tanto outliers como drift en series de tiempo provenientes de sensores industriales. A continuación se resumen las conclusiones globales del trabajo:

- **Desarrollo de dos módulos complementarios y autónomos** Se implementaron dos pipelines independientes uno para outliers y otro para drift que abordan problemáticas distintas pero complementarias. Esta separación permite integrar cada módulo en Poseidón de manera flexible, sin dependencias entre sí y con configuraciones completamente personalizables. Permitiendo por ejemplo aplicar el módulo de drift solo a las variables que requieren los modelos predictivos
- **Selección fundamentada de métricas de evaluación** La inclusión de métricas temporales en la evaluación de drift permitió capturar un aspecto crítico para la operación: la rapidez en la detección. La métrica compuesta $F1_{mixto}$ demostró ser la más representativa para comparar métodos y se adoptó como criterio estándar.
- **Sistema preparado para integración operativa** Ambos pipelines generan salidas estructuradas y reproducibles en formato .csv, con etiquetado por variable, umbrales aplicados y configuración efectiva utilizada. Esto facilita su incorporación en flujos actuales de Poseidón y habilita futuras automatizaciones.
- **Base técnica sólida para futuras extensiones** La modularidad del sistema y su diseño parametrizable permiten incorporar nuevos métodos, estrategias o fuentes de datos sin reescribir el pipeline. Asimismo, el trabajo deja bases claras para una futura extensión multivariada o una detección en tiempo real.

9 LIMITACIONES

9.1 Limitación de la Detección de Outliers

Ambos modelos cuentan con limitaciones, por una parte el modelo basado en series de tiempo, es la utilizar cuantiles como treshold. Esto obliga a tener una cierta cantidad de outliers, lo que aumenta la cantidad de falsos positivos.

Por otra parte, el modelo basado en diferenciación tiene la limitación de utilizar como treshold la desviación estándar, este método puede ser poco efectivo en cambios de volatilidad muy bruscas. Una mejora al modelo puede ser utilizar otros métodos para generar estos umbrales, si bien se probaron algunos como las sliding windows o el método de la desviación absoluta de la mediana. Ninguno obtuvo mejores resultados que la desviación estándar

9.2 Limitación de la Detección de Drift

Aunque el módulo de drift obtuvo buenos resultados en los escenarios evaluados, presenta algunas limitaciones inherentes a su diseño y a la naturaleza del problema:

- **Sensibilidad al tamaño de ventana** El sistema requiere un tamaño de ventana suficiente para estabilizar las métricas estadísticas. Ventanas muy pequeñas generan variabilidad en el score, mientras que ventanas grandes introducen retrasos inevitables en la detección. Este balance afecta directamente la magnitud de $F1_{time}$.
- **Limitación de la estrategia estacional** La estrategia *Seasonal* depende completamente de la correcta identificación del ciclo operativo (por ejemplo, 24 horas). Ciclos mal definidos o no estacionarios pueden producir degradación en la detección y valores más bajos en la componente temporal.
- **Validación limitada a datos sintéticos** Debido a la falta de etiquetas reales en los datos de operación, la validación se realizó exclusivamente sobre series sintéticas. Si bien estas permiten evaluar casos controlados, no garantizan que el desempeño observado se traslade de manera idéntica a entornos reales de planta.

BIBLIOGRAFÍA

- [Alghushairy et al., 2021] Alghushairy, O., Alsini, R., Soule, T., and Ma, X. (2021). A review of local outlier factor algorithms for outlier detection in big data streams. *Big Data and Cognitive Computing*, 5(1):1.
- [Almeida et al., 2021] Almeida, J., Ferreira, C., and Gama, J. (2021). On the importance of early drift detection. In *Proceedings of the 2021 IEEE International Conference on Big Data (BigData)*, pages 1232–1241. IEEE.
- [Baena-García et al., 2006] Baena-García, M., del Campo-Avila, J., Fidalgo, R., Bifet, A., Gavalda, R., and Morales-Bueno, R. (2006). Early drift detection method. In *Fourth International Workshop on Knowledge Discovery from Data Streams*.
- [Baranwal et al., 2025] Baranwal, T., Das, A., Varada, S., Das, S., and Haider, M. R. (2025). Machine learning-based anomaly detection of correlated sensor data: An integrated principal component analysis-autoencoder approach. *arXiv preprint arXiv:2505.24044*.
- [Erhan et al., 2020] Erhan, D., Tuncer, T., Kaya, M., and Zaluska, E. (2020). Smart anomaly detection in sensor systems: A multi-perspective review. *Journal of Sensor and Actuator Networks*, 9(4):58.
- [Palma, 2016] Palma, W. (2016). *Time Series Analysis*. Wiley Series in Probability and Statistics. John Wiley & Sons, Hoboken, New Jersey.
- [Takeuchi and Yamanishi, 2006] Takeuchi, J.-i. and Yamanishi, K. (2006). A unifying framework for detecting outliers and change points from non-stationary time series data. In *Proceedings of the 2006 SIAM International Conference on Data Mining*, pages 560–564. SIAM.

10 ANEXOS

10.1 Fundamentación Teórica de la Métrica Mixta para Drift

La literatura en *concept drift detection* señala que el desempeño de un detector no puede evaluarse únicamente mediante métricas de calidad como *Precision*, *Recall* o *F1*. Estas métricas miden la capacidad del modelo para identificar correctamente la existencia de un episodio, pero ignoran la dimensión temporal: cuán temprano se detecta el drift.

En aplicaciones reales, especialmente cuando los datos alimentan modelos predictivos o sistemas operacionales, una detección tardía puede ser tan problemática como no detectar el evento. Por esta razón, múltiples trabajos señalan que calidad y rapidez deben evaluarse de manera conjunta.

Entre los trabajos más relevantes destacan:

- Baena-García et al. (2006), “Early Drift Detection Method (EDDM)” [Baena-García et al., 2006].
- Almeida et al. (2021), “On the Importance of Early Drift Detection” [Almeida et al., 2021].

En particular, este último trabajo demuestra empíricamente que las métricas compuestas más estables utilizan ponderaciones donde la calidad aporta entre 0,7 y 0,9, mientras que la rapidez contribuye entre 0,1 y 0,3. Estas proporciones evitan que la evaluación se sesgue hacia detectores extremadamente rápidos pero con alta tasa de falsos positivos.

Siguiendo estas recomendaciones, en este trabajo se adopta una ponderación intermedia dentro del rango sugerido:

$$F1_{\text{mixto}} = 0,85 \cdot F1 + 0,15 \cdot F1_{\text{time}}.$$

Esta métrica permite capturar simultáneamente la calidad de detección y la oportunidad de respuesta, proporcionando una medida única y más representativa del desempeño operativo del sistema de detección de drift.

10.2 Visualización Nubes de Outliers

Varias veces hablamos del comportamiento nubes de outliers, veamos visualmente este comportamiento:




Figura 10.1: Serie con nube de outliers.

Como se observa en la Figura 10.2, se ve un comportamiento normal, hasta que hay una gran cantidad de outliers seguidos.