



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
INSTITUTO DE INGENIERÍA MATEMÁTICA Y COMPUTACIONAL
IMT2270 - PROYECTO FINAL DE GRADO

Entrega 2 – Sistema de Evaluación Automática para Sensores Hídricos

14 de septiembre de 2025

Franco Chiappe - Vicente Garay - Ziyu Guo

1. Situación Actual

Ainwater es una startup chilena de base tecnológica que desarrolla soluciones de inteligencia artificial para la optimización de plantas de tratamiento de agua. Su principal producto es la plataforma *Poseidón*, que permite monitorear en tiempo real el funcionamiento de plantas de agua potable, residual e industrial, entregando alertas predictivas y recomendaciones de operación.

El control de calidad de datos en Ainwater se realiza actualmente de forma manual y reactiva, lo que genera retrasos en la detección de fallas, ausencia de indicadores formales y un impacto directo en la confiabilidad de los modelos predictivos integrados en la plataforma *Poseidón*.

Además, existen experiencias internacionales que muestran cómo la industria está avanzando hacia soluciones similares. Por ejemplo, Veolia integra módulos de gestión inteligente del agua en su solución de (Smart Water Management). De forma similar, Schneider Electric ofrece (EcoStruxure Water and Wastewater Solutions) con validación automática de datos, y Siemens ha desarrollado iniciativas de (Digitalization in Water Industry) orientadas al control en tiempo real.

Fuentes de datos: actualmente contamos con tres archivos csv separados, uno por cada planta piloto. Estos archivos provienen de sensores distintos y no comparten un esquema uniforme de columnas, lo que impide un análisis conjunto directo. Cada planta será trabajada de manera independiente, respetando sus particularidades de variables y procesos, para luego comparar los enfoques metodológicos aplicados.

Principales dificultades actuales:

- Lagunas frecuentes en los datos minuto a minuto.
- Valores atípicos extremos o físicamente imposibles.
- Heterogeneidad de formatos en los archivos de datos.

Acceso a datos: obtenemos datos históricos de sensores de caudal, nivel de pozos, pH, temperatura, conductividad, entre otros, a través de la infraestructura de Ainwater.

Stakeholders: Constanza Córdova (Líder de Ciencia de Datos) y Yaniela Fernández (Data Engineer) participan en reuniones semanales vía Google Meet e igualmente en un canal de Slack, lo que permite comunicación rápida y coordinación de entregas intermedias.

2. Entregables esperados

- **Hitos:** Entregas con la contraparte, incluyen principalmente informes de avance y evolución del proyecto. Constan de tres entregas intermedias que incluyen diagnóstico de datos, pruebas de modelos y análisis de métricas, de manera que la contraparte pueda revisar avances de forma formal y trazable.
- **Conjunto de modelos:** la entrega final contempla un portafolio de distintos modelos de detección de anomalías (outliers, drift, lagunas), acompañados de sus métricas de desempeño y umbrales definidos. Esto permitirá a la contraparte seleccionar aquellos que mejor se ajusten a las características específicas de cada planta. Todo esto en el formato de Jupyter Notebooks.
- **Documentación de Resultado:** La entrega de los Jupyter Notebooks busca que estos sean claros y reproducibles que contengan limpieza, procesamiento de datos, implementación de modelos, métricas y visualización de anomalías, asegurando trazabilidad y transparencia en el trabajo.
- **Prototipo de dashboard (opcional):** actualmente se están explorando alternativas para una visualización integrada en formato intuitivo. Sin embargo, este no constituye el objetivo principal del proyecto, sino una posible extensión que se evaluará en función de los tiempos y recursos disponibles.

Este esquema asegura tanto la trazabilidad técnica como la entrega de resultados prácticos y utilizables para Ainwater, manteniendo el foco en los modelos y el procesamiento de datos.

3. Objetivos

3.1. Generales

1. **Realizar un análisis exploratorio de datos:** comprender patrones, la naturaleza de los datos de sensores y detectar outliers evidentes de manera visual.

2. **Revisar literatura relevante:** identificar metodologías aplicadas en contextos similares (p. ej., detección de anomalías en datos minuto a minuto de sensores industriales).
3. **Implementar modelos iniciales:** aplicar métodos estadísticos y de machine learning no supervisado en los datos de las plantas.
4. **Testear los modelos:** ajustar parámetros y evaluar su desempeño en función de los objetivos de detección de outliers y drift.
5. **Seleccionar los mejores modelos:** comparar resultados y priorizar aquellos con mayor precisión y menor tasa de falsos positivos.
6. **Definir umbrales y métricas:** establecer criterios cuantitativos (precisión, recall, FPR) y umbrales de decisión para la detección de anomalías.
7. **Construir un pipeline de evaluación:** integrar los modelos seleccionados en un flujo reproducible de análisis.
8. **Entregar un portafolio de modelos validados:** proveer a la contraparte un conjunto de modelos con métricas y umbrales, de manera que puedan elegir cuáles aplicar según el tipo de planta.
9. **Explorar la construcción de un dashboard:** de manera opcional, se evaluará la implementación de un prototipo que permita visualizar anomalías e indicadores de calidad de forma integrada. Esta meta no es prioritaria, pero se está revisando y probando en paralelo.

3.2. Particulares

Los objetivos particulares corresponden a tareas concretas en el corto plazo, alineadas con la planificación en Trello y Google Calendar:

- Procesar de forma independiente los datos de cada una de las tres plantas, generando flujos de limpieza y preparación específicos para cada archivo.
- Implementar el método *Matrix Profile* para análisis de drift.
- Implementar el enfoque *Unifying Framework* para detección estadística de drift.
- Evaluar el desempeño de modelos de outliers.
- Realizar análisis exploratorio de drift con métricas estadísticas.
- Etiquetar outliers manualmente con la herramienta entregada por la contraparte.
- Mostrar resultados de detección en gráficos y reportes preliminares.

4. Solución Propuesta y Metodología

El desarrollo contempla las siguientes etapas:

1. **Procesamiento inicial:** además de las tareas técnicas de limpieza de datos provenientes de tres archivos separados (uno por cada planta), resampling y estandarización de unidades, esta etapa incluyó un trabajo de comprensión del contexto físico-químico de las plantas. Fue necesario interpretar correctamente los procesos involucrados, entender abreviaciones propias de las tablas de sensores y reconocer que se trata de tres plantas distintas, no comparables directamente entre sí. Este análisis preliminar permitió definir qué significa contar con “datos buenos”: series temporales consistentes, sin valores imposibles, sin lagunas extensas y comparables entre variables.
2. **Definición de anomalías:** establecer criterios claros para identificar outliers, drift y lagunas.
3. **Implementación de modelos y métricas:** aplicar métodos estadísticos (IQR, KS-test, PSI) y de machine learning no supervisado (LOF, Autoencoders). Cada modelo será evaluado con métricas de desempeño como precisión, recall y tasa de falsos positivos.
4. **Selección de modelos y umbrales:** a partir de las métricas se priorizarán los modelos más adecuados para cada sensor, definiendo además umbrales de score que permitan clasificar detecciones.
5. **Evaluación comparativa:** analizar resultados por sensor y contrastar la detección automática con etiquetas generadas manualmente mediante el etiquetador visual entregado por la contraparte.
6. **Visualización preliminar:** presentar resultados en Jupyter notebooks con gráficos y reportes automatizados. En este punto también hemos explorado el uso de la librería Evidently, específicamente su componente **Report**, que permite generar informes interactivos en formato HTML. Esta alternativa se aproxima al tipo de entregable que la contraparte mencionó en su propuesta inicial, al combinar gráficos y métricas en un mismo archivo navegable. Actualmente se está evaluando la posibilidad de evolucionar esta línea hacia un prototipo de dashboard, aunque este constituye un objetivo complementario y no el foco central del proyecto.
7. **Horizontes temporales:** el análisis se enfocará inicialmente en datos minuto a minuto, evaluando también su agregación a horizontes horarios o diarios para estudiar el efecto del periodo de tiempo en la detección de anomalías.

5. Planificación

La planificación del proyecto se gestiona de manera centralizada en Trello, donde se crean todas las tareas, se asignan responsables y se organizan en función de los hitos del semestre.

Cada actividad queda vinculada a un integrante del equipo, lo que facilita la coordinación interna y el seguimiento del trabajo con la contraparte.

Para mejorar la visualización y organización temporal, los calendarios generados en Trello se sincronizan con Google Calendar. De esta forma, además de la vista de tableros y tarjetas en Trello, contamos con una representación visual más clara de las actividades distribuidas a lo largo de los días y semanas. Esta integración permite mantener un control preciso de los plazos y al mismo tiempo disponer de una visión consolidada de la carga de trabajo.

Principales actividades programadas:

- Investigar y revisar literatura sobre métodos de detección de drift.
- Implementar y testear modelos estadísticos iniciales.
- Evaluar el etiquetador manual entregado por la contraparte.
- Comparar resultados de modelos con métricas definidas.
- Procesar datos de las tres plantas por separado y documentar diferencias.
- Visualizar resultados preliminares en notebooks y reportes.
- Preparar y entregar hitos formales a la contraparte.

Este cronograma no se limita a tres semanas, sino que se extiende en hitos sucesivos hasta el cierre del semestre. La integración entre Trello y Google Calendar asegura tanto la trazabilidad de tareas como una organización visual clara, optimizando la comunicación y coordinación con Ainwater.




Figura 1: Planificación detallada del proyecto para septiembre, gestionada en Trello y visualizada en Google Calendar.