



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
INSTITUTO DE INGENIERÍA MATEMÁTICA Y COMPUTACIONAL  
IMT2270 - PROYECTO FINAL DE GRADO

# Entrega 3 – Sistema de Evaluación Automática para Sensores Hídricos

30 de octubre de 2025

Franco Chiappe - Vicente Garay - Ziyu Guo

---

## 1. Contexto

Ainwater es una startup chilena de base tecnológica que desarrolla soluciones de inteligencia artificial para la optimización de plantas de tratamiento de agua. Su principal producto es la plataforma *Poseidón*, que permite monitorear en tiempo real el funcionamiento de plantas de agua potable, residual e industrial, entregando alertas predictivas y recomendaciones de operación.

El control de calidad de datos en Ainwater se realiza actualmente de forma manual y reactiva, lo que genera retrasos en la detección de fallas, ausencia de indicadores formales y un impacto directo en la confiabilidad de los modelos predictivos integrados en la plataforma *Poseidón*.

Además, existen experiencias internacionales que muestran cómo la industria está avanzando hacia soluciones similares. Por ejemplo, Veolia integra módulos de gestión inteligente del agua en su solución de (Smart Water Management). De forma similar, Schneider Electric ofrece (EcoStruxure Water and Wastewater Solutions) con validación automática de datos, y Siemens ha desarrollado iniciativas de (Digitalization in Water Industry) orientadas al control en tiempo real.

**Fuentes de datos:** actualmente contamos con tres archivos csv separados, uno por cada planta piloto. Estos archivos provienen de sensores distintos y no comparten un esquema uniforme de columnas, lo que impide un análisis conjunto directo. Cada planta será trabajada de manera independiente, respetando sus particularidades de variables y procesos, para luego comparar los enfoques metodológicos aplicados.

### Principales dificultades actuales:

- Lagunas frecuentes en los datos minuto a minuto.
- Valores atípicos extremos o físicamente imposibles.
- Heterogeneidad de formatos en los archivos de datos.

**Acceso a datos:** obtenemos datos históricos de sensores de caudal, nivel de pozos, pH, temperatura, conductividad, entre otros, a través de la infraestructura de Ainwater.

**Stakeholders:** Constanza Córdova (Líder de Ciencia de Datos) y Yaniela Fernández (Data Engineer) participan en reuniones semanales vía Google Meet e igualmente en un canal de Slack, lo que permite comunicación rápida y coordinación de entregas intermedias.

## 2. Solución Propuesta y Metodología

El desarrollo contempla las siguientes etapas:

1. **Procesamiento inicial:** además de las tareas técnicas de limpieza de datos provenientes de tres archivos separados (uno por cada planta), resampling y estandarización de unidades, esta etapa incluyó un trabajo de comprensión del contexto físico-químico de las plantas. Fue necesario interpretar correctamente los procesos involucrados, entender abreviaciones propias de las tablas de sensores y reconocer que se trata de tres plantas distintas, no comparables directamente entre sí. Este análisis preliminar permitió definir qué significa contar con “datos buenos”: series temporales consistentes, sin valores imposibles, sin lagunas extensas y comparables entre variables.
2. **Definición de anomalías:** establecer criterios claros para identificar outliers, drift y lagunas.
3. **Implementación de modelos y métricas:** aplicar métodos estadísticos (diferenciación, KS-test, PSI). Cada modelo será evaluado con métricas de desempeño como precisión, recall y tasa de falsos positivos.
4. **Selección de modelos y umbrales:** a partir de las métricas se priorizarán los modelos más adecuados para cada sensor, definiendo además umbrales de score que permitan clasificar detecciones.
5. **Evaluación comparativa:** analizar resultados por sensor y contrastar la detección automática con etiquetas generadas manualmente mediante el etiquetador visual entregado por la contraparte.
6. **Visualización preliminar:** presentar resultados en Jupyter notebooks con gráficos y reportes automatizados. En este punto también hemos explorado el uso de la librería Evidently, específicamente su componente **Report**, que permite generar informes interactivos en formato HTML. Esta alternativa se aproxima al tipo de entregable que la contraparte

mencionó en su propuesta inicial, al combinar gráficos y métricas en un mismo archivo navegable. Actualmente se está evaluando la posibilidad de evolucionar esta línea hacia un prototipo de dashboard, aunque este constituye un objetivo complementario y no el foco central del proyecto.

7. **Horizontes temporales:** el análisis se enfocará inicialmente en datos minuto a minuto, evaluando también su agregación a horizontes horarios o diarios para estudiar el efecto del periodo de tiempo en la detección de anomalías.

## 3. Avances preliminares

### 3.1. Modelos de detección de Outliers

Primero veamos los predictores que utilizaremos para la detección de outliers:

- Serie de tiempo: Este modelo se basa en ajustar un modelo de serie de tiempo, ejemplo: AR, ARMA, ARIMA, etc. Y después ver los residuos del modelo (cuanto se aleja la predicción del valor real)
- Diferenciación estadística: Este modelo se basa en analizar la diferencia del dato con su predecesor y su sucesor, para después comparar con las diferencias históricas en la serie.

#### 3.1.1. Basado en modelos de serie de tiempo

Este enfoque ajusta un modelo autorregresivo (p.ej.  $AR(p)$ ) sobre la serie y utiliza los **residuos** para construir un *outlier score* y un *change score* (detección de cambios en patrón operativo) con parámetros de suavizado y umbrales por cuantiles. A continuación se detallan los supuestos, parámetros y la forma de cálculo del puntaje, tal como se implementó en el proyecto.

Este modelo se basa en (Yamanishi & Takeuchi, 2006), el paper habla de un modelo unificado para la detección de outliers. entrega un outlier score y un change score

El modelo necesita ciertos parámetros para ser entrenado, primero pide un modelo de serie de tiempo, en este caso utilicé el modelo  $AR(2)$ , este puede cambiar según cada variable, no necesita ser un modelo en específico.

Por otro lado el modelo pide:

- $\alpha \in [0, 1]$ : Este parámetro se llama factor de suavizado, sirve para calcular la varianza dinámica de los residuos, entre más pequeño el  $\alpha$ , más lento se actualiza la varianza.

Si bien un valor bajo es bueno, ya que tiene una larga memoria, puede empeorar el modelo ante un época con mucha variabilidad.

- $quantile \in (0, 1)$ : Este parámetro pide el umbral de cuantil para clasificarlo como outlier, es decir si se entrega  $quantile = 0.995$ , todo punto con outlier score sobre el cuantil 0.995 será clasificado como outlier
- $factor\_olvido \in (0, 1)$ : Controla la rapidez con la que el algoritmo *changefinder* se adapta a nuevos datos, un valor menor (ej: 0.01) le da más peso a valores recientes, pero empeora su rendimiento cuando hay ruido. En cambio un valor más grande le da más peso al pasado, pero pierde eficacia en épocas con mayor variabilidad
- $lag\_cambio \in \mathbb{Z}^+$ : Para entender este parámetro, hay que entender el algoritmo *changefinder*, este funciona con un modelo AR, por lo tanto  $lag\_cambio$  es el componente AR del algoritmo
- $suavizado \in \mathbb{Z}^+$ : Es el tamaño de media móvil que aplica el algoritmo, un valor pequeño (ej: 1), puede generar ruido, en cambio un valor más grande (ej: 8) reduce falsos positivos, pero valores muy altos pueden hacer que el algoritmo demore más.
- $change\_quantile \in (0, 1)$ : Misma idea que  $quantile$  solo que se basa en el cuantil de  $change\_score$

Ahora que ya conocemos los parámetros, veamos como se calcula *outlier\_score*:

Sea  $r_t$ :

$$r_t = x_t - \hat{x}_t$$

Es decir  $r_t$  es el error de la predicción de la serie de tiempo. Ahora veamos como se estima la varianza:

$$s_t^2 = (1 - \alpha)s_{t-1}^2 + \alpha r_t^2$$

Por último el paper asume que  $r_t \sim N(0, s_t^2)$ , con todo esto ya podemos ver como se calcula *outlier\_score*:

$$outlier\_score = \frac{1}{2}(\log(2\pi s_t^2) + \frac{r_t^2}{s_t^2})$$

La cual se basa en la menor log-verosimilitud de la densidad de  $r_t$ .

Y el *change\_score* funciona con la librería *changefinder* y detecta cambios con un algoritmo basado en el error del modelo AR

### 3.1.2 Basado en diferenciación estadística

El siguiente modelo se basa en la diferenciación estadística, explicando de manera sencilla, lo que hace es tomar el dato, ver la menor diferencia entre el dato anterior y el siguiente y compararlo con la desviación estándar de la diferencia centrada pasada. Este utiliza dos parámetros:

- $\lambda\_centrada \in \mathbb{Z}^+$ : Este número sirve para comparar el dato con la desviación estándar pasada de la diferencia centrada, es cuantas veces tiene que estar alejado para marcarlo como outlier.
- $k \in \mathbb{Z}^+$ : Misma idea que el parámetro anterior, solo que no se multiplica por la std, si no es que tanta diferencia tiene que haber con el dato anterior para marcarlo como outlier, puede ser la diferencia entre el cuantil 50 y 99, o un número definido.

Idealmente  $k$  debe ser mayor a  $\lambda\_centrada \cdot std$

Veamos como se vería de manera matemática, siendo la data  $y_t$ :

$$\begin{aligned} x_t &= \min(|y_t - y_{t-1}|, |y_t - y_{t+1}|) \\ \text{if } x_t &\geq std \cdot \lambda\_centrada \rightarrow \text{outlier} \\ \text{elif } |y_t - y_{t-1}| &\geq k \rightarrow \text{outlier} \end{aligned}$$

## 3.2 Modelos de detección de Drift

El drift se define como una variación significativa en la distribución estadística de una variable respecto a su comportamiento histórico. La comparación se realiza entre una ventana actual y una referencia histórica, y la diferencia se resume en un drift score calculado con distancias estadísticas, como lo pueden ser Wasserstein o Kolmogorov–Smirnov, entre otras que se pueden seleccionar. En este proyecto se implementaron tres estrategias determinísticas para construir la referencia.

### 3.2.1 Decay reference (exponencial)

Prioriza la historia reciente mediante pesos exponenciales. Se toma el prefijo más reciente del histórico cuya masa acumulada alcanza un umbral objetivo.

**Parámetros principales:**

- `DECAY_HALF_LIFE_HOURS`: tiempo de vida media de los pesos (p. ej.  $24 \times 7$  horas).
- `DECAY_WEIGHT_MASS`: masa acumulada objetivo del prefijo (p. ej. 0,95).

Dado un índice temporal y el tiempo actual  $t$ , se asigna a cada observación un peso  $w = \exp(-\Delta t/\tau)$  con  $\tau$  definido por la vida media. Se ordena por que tan reciente es y se toma el prefijo mínimo cuya masa acumulada de  $w$  supere `DECAY_WEIGHT_MASS`.

- (+) Responde rápido a cambios recientes y no requiere etiquetas.
- (−) Puede sobre-reaccionar a ruido si la vida media es demasiada corta.

**Cuándo usar.** Sensores con cambios de patrón operativo frecuentes.

### 3.2.2 Golden reference (ventanas estables)

Construye una “ventana dorada” concatenando  $k$  ventanas históricas más estables (menor dispersión robusta), que sirven de referencia “ideal” del comportamiento.

### Parámetros principales:

- `GOLDEN_WIN`: ancho de cada ventana histórica (p. ej. "30min").
- `GOLDEN_STEP`: paso entre inicios de ventana (p. ej. "10min").
- `GOLDEN_K`: cantidad de ventanas más estables a concatenar (p. ej.  $k = 40$ ).

Para cada ventana se calcula un score robusto (mediana e IQR por columna numérica, se normaliza por mediana absoluta para evitar escalas) y se seleccionan las  $k$  ventanas con menor score.

- (+) Muy robusto a ruido y a picos aislados, excelente estabilidad del baseline.
- (−) Puede reaccionar más lento ante cambios de patrón operativo recientes.

**Cuándo usar.** Variables con comportamiento estacional o con ruido alto donde interesa robustez del baseline.

### 3.2.3 Seasonal reference (estacionalidad)

**Idea.** Compara la ventana actual con segmentos históricos de la misma hora del día y día de semana, dentro de un horizonte de  $W$  semanas hacia atrás.

#### Parámetro principal:

- `SEASONAL_WEEKS_BACK`: cantidad de semanas hacia atrás utilizadas para construir la referencia (ej.;,  $W = 12$ ).
- (+) Captura patrones cíclicos con buena precisión temporal.
- (−) Dependiente de suficiente historia y puede fallar si hay cambios operativos de calendario.

**Cuándo usar.** Series con patrones horarios y semanales claros (flujo, temperaturas, cargas periódicas). El **drift score** por columna se obtiene con `Evidently` (`ValueDrift` y `DataDriftPreset`) aplicando un test/medida de distancia configurable:

- `NUM_METHOD`: {`auto`, `ks`, `wasserstein`, `psi`, `anderson`, `cramer`, `mannwhitney`}.
- `NUM_THRESHOLD` (opcional): umbral explícito para la métrica seleccionada.

Por defecto `NUM_METHOD = auto`, dejando que el preset elija el método más adecuado por tipo de variable.

## 3.3 Resultados preliminares

### 3.3.1 Outliers

Para medir la calidad del ajuste utilizaremos métricas basadas en los true positive, false positive, true negative y false negative.

Específicamente utilizaremos las siguientes métricas:

- $Precision = \frac{TP}{TP+FP}$  es decir mide de todos los puntos marcados como outliers, cuantos realmente eran outliers
- $Recall = \frac{TP}{TP+FN}$  mide la cantidad de aciertos
- $F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$

Para esto seleccionaremos 4 variables de la planta 1 y 4 de la planta 2, tomando estas estadísticas a mano, es decir se ajustara el modelo y se revisara un gráfico por día viendo los aciertos y fallos.

Esto ya que ambos modelos se ven perjudicados cuando hay 2 o más outliers juntos, ya que solo detectan el primero.

Veamos como funcionaron los modelos, tomando datos del 06-01 hasta 08-09:

Cuadro 1: Resultados de Métricas TP, FP, FN para Modelos DIFF y AR

| Modelo | Variable                         | TP        | FP | FN        |
|--------|----------------------------------|-----------|----|-----------|
| DIFF   | pH coagulación entrada DAF       | 11 (+149) | 8  | 2         |
|        | pH Clarificado DAF (Tk.80m3)     | 4         | 2  | 2         |
|        | pH salida a Parshall 02          | 1         | 1  | 0         |
|        | Flujo Salida de Lodo Sed. Sec. 3 | 27 (+245) | 12 | 1         |
|        | Flujo Afluente PTAR              | 1         | 0  | 1         |
|        | Flujo Cámara de contacto 2       | 1         | 0  | 1         |
| AR     | pH coagulación entrada DAF       | 10 (+59)  | 12 | 3 (+90)   |
|        | pH Clarificado DAF (Tk.80m3)     | 6         | 15 | 0         |
|        | pH salida a Parshall 02          | 0         | 20 | 1         |
|        | Flujo Salida de Lodo Sed. Sec. 3 | 15 (+94)  | 4  | 13 (+151) |
|        | Flujo Afluente PTAR              | 2         | 15 | 0         |
|        | Flujo Cámara de contacto 2       | 2         | 17 | 0         |

Los paréntesis indican 'nubes de outliers', es decir muchos outliers juntos, para el calculo de métricas solo se van a considerar como 1 un outlier por cada nube.

Ahora veamos las métricas obtenidas:

Cuadro 2: Métricas de Evaluación (Precisión, Recall, F1) para Modelos DIFF y AR

| Modelo | Variable                         | Precisión | Recall | F1-Score |
|--------|----------------------------------|-----------|--------|----------|
| DIFF   | pH coagulación entrada DAF       | 0.579     | 0.846  | 0.688    |
|        | pH Clarificado DAF (Tk_80m3)     | 0.667     | 0.667  | 0.667    |
|        | pH salida a Parshall 02          | 0.500     | 1.000  | 0.667    |
|        | Flujo Salida de Lodo Sed. Sec. 3 | 0.692     | 0.964  | 0.806    |
|        | Flujo Afluente PTAR              | 1.000     | 0.500  | 0.667    |
|        | Flujo Cámara de contacto 2       | 1.000     | 0.500  | 0.667    |
| AR     | pH coagulación entrada DAF       | 0.455     | 0.769  | 0.572    |
|        | pH Clarificado DAF (Tk_80m3)     | 0.286     | 1.000  | 0.445    |
|        | pH salida a Parshall 02          | 0.000     | 0.000  | 0.000    |
|        | Flujo Salida de Lodo Sed. Sec. 3 | 0.789     | 0.536  | 0.638    |
|        | Flujo Afluente PTAR              | 0.118     | 1.000  | 0.211    |
|        | Flujo Cámara de contacto 2       | 0.105     | 1.000  | 0.190    |

En conclusión el mejor modelo es el basado en la diferenciación, es el con menor falsos positivos, y menor falsos negativos.

Si se desea se pueden obtener menor falsos negativos, ajustando un  $\lambda_{centrada}$  menor, con el problema de obtener mayor falsos positivos, pero así detectando todos los outliers.

### 3.3.2 Drift

El drift corresponde a un cambio significativo en la distribución estadística de una variable al comparar una ventana actual con una referencia histórica. A diferencia del caso de outliers, aquí no se dispone de etiquetas que indiquen de forma inequívoca cuándo un cambio es “real”, por tanto, la evaluación se realiza de manera no supervisada y estadística.

Se utilizan cuatro métodos estadísticos principales:

- **KS / Mann–Whitney:** pruebas de hipótesis basadas en p-valores, sensibles a diferencias en forma o posición.
- **PSI:** mide divergencia entre histogramas, útil para monitoreo continuo.
- **Wasserstein:** distancia promedio entre cuantiles, capta desplazamientos graduales en la media.

KS, PSI, Wasserstein y Mann–Whitney son métodos estadísticos de comparación entre ventana actual y referencia.

Cada una se aplica sobre distintas estrategias de referencia (Decay, Golden y Seasonal), obteniendo un porcentaje de columnas con drift detectado (**drift\_rate\_%**) para cada combinación.



La Tabla 3 muestra el promedio de columnas con drift detectado según estrategia y método estadístico.

Cuadro 3: Drift rate promedio (%) por estrategia  $\times$  métodos estadísticos para cada planta

| Planta   | Estrategia | KS    | PSI  | Wasserstein | Mann–Whitney |
|----------|------------|-------|------|-------------|--------------|
| Planta 1 | Decay      | 66.7  | 80.0 | 53.3        | 33.3         |
|          | Golden     | 100.0 | 92.3 | 92.3        | 46.2         |
|          | Seasonal   | 73.3  | 73.3 | 60.0        | 40.0         |
| Planta 2 | Decay      | 62.5  | 75.0 | 56.3        | 31.3         |
|          | Golden     | 85.7  | 92.9 | 89.3        | 50.0         |
|          | Seasonal   | 70.8  | 66.7 | 58.3        | 45.8         |
| Planta 3 | Decay      | 60.0  | 66.7 | 53.3        | 26.7         |
|          | Golden     | 88.2  | 94.1 | 88.2        | 52.9         |
|          | Seasonal   | 68.8  | 75.0 | 62.5        | 37.5         |

Para evaluar la coherencia entre los métodos utilizados, se calculó el porcentaje de coincidencia entre pares de métodos estadísticos, considerando las variables clasificadas con drift. La Tabla 4 muestra dicha coincidencia promedio por planta.

Cuadro 4: Coincidencia (%) entre métodos estadísticos de drift por planta

| Planta   | PSI–Wass. | KS–MWU | KS–PSI | KS–Wass. | MWU–PSI | MWU–Wass. |
|----------|-----------|--------|--------|----------|---------|-----------|
| Planta 1 | 83.5      | 41.2   | 62.4   | 60.1     | 54.6    | 58.9      |
| Planta 2 | 79.8      | 35.7   | 59.2   | 55.0     | 51.3    | 57.6      |
| Planta 3 | 81.7      | 38.9   | 61.0   | 58.5     | 53.7    | 60.2      |

Estos resultados confirman una **alta correspondencia entre PSI y Wasserstein**, mientras que KS y Mann–Whitney muestran menor solapamiento con el resto. Esto sugiere que PSI y Wasserstein son más consistentes para detectar cambios continuos, mientras que KS y Mann–Whitney se comportan como métodos más específicos.

En general, **Golden–PSI** se posiciona como la combinación más sensible y consistente entre plantas, mientras que **Seasonal–Wasserstein** resulta más estable en series con estacionalidad marcada. Los valores coincidentes entre PSI y Wasserstein respaldan su uso conjunto para la detección de drift gradual.

## 4. Dificultades/soluciones

### 4.1 Outliers

La mayor complicación fue encontrar métodos adecuados a nuestras variables, al ser plantas independientes y datos no correlacionados, gran parte de la literatura no era útil. También los métodos estadísticos típicos no funcionaban, al ser muchos datos y pocos outliers.

Al final buscando papers se encontró el (Yamanishi & Takeuchi, 2006) que fue bastante útil, y para el método de diferenciación fue en base a prueba y error, además de pensar mucho en el problema, una gran ayuda fue el ramo de serie de tiempo, en donde se utiliza bastante la diferenciación, lo que ayudo a construir un modelo adecuado al problema.

### 4.2 Drift

En la detección de drift la principal dificultad ha sido controlar la sensibilidad de las métricas ante ruido y variabilidad natural en los datos. En muchas variables los valores extremos o cambios puntuales provocan que PSI y Wasserstein indiquen drift, aun cuando se trata solo de fluctuaciones locales. Esto dificulta distinguir entre un cambio real en el proceso y una variación temporal propia del sensor.

Otra dificultad importante ha sido la selección de la referencia histórica. La estrategia Golden tiende a generar tasas de drift elevadas al comparar con ventanas demasiado estables, mientras que Decay responde mejor a cambios recientes y Seasonal requiere suficiente historia para funcionar correctamente.

También se observaron limitaciones técnicas de cada métrica: PSI depende del número de bins y puede divergir con frecuencias bajas, KS es sensible al tamaño muestral y detecta cambios mínimos, y en variables binarias el test Mann–Whitney pierde validez. Estos aspectos serán considerados en la próxima etapa, al incorporar filtros de ruido y ajustes de umbrales dinámicos para mejorar la estabilidad de los resultados.

## 5. Próximos Pasos

- Automatizar umbrales dinámicos por columna y estrategia, con revisión periódica y control de tasa de alertas objetivo.
- Cobertura y calidad de ventana: integrar indicadores mínimos de tamaño muestral y cobertura para marcar resultados no concluyentes.
- Reporte unificado por planta: consolidar tablas “Top- $k$  variables” con mayor score + breve hipótesis operativa.

## 6. Citas

Takeuchi, J.-I., & Yamanishi, K. (2006). *A unifying framework for detecting outliers and change points from non-stationary time series data*. In *Proceedings of the 2006 SIAM International Conference on Data Mining* (pp. 560–564). Association for Computing Machinery. <https://doi.org/10.1145/775047.775148>