



OPTIMIZACIÓN DE MODELOS PREDICTIVOS MEDIANTE DETECCIÓN DE OUTLIERS Y DRIFT

INTELIGENCIA ARTIFICIAL PARA UNA GESTIÓN EFICIENTE Y SOSTENIBLE DEL AGUA

Ainwater desarrolla soluciones SaaS para optimizar la operación de plantas de tratamiento de agua.


Su tecnología se utiliza en instalaciones que procesan más de 1 millón de m³ diarios.

Escala operacional en cifras

1 Millón m³



400 Piscinas
Olímpicas



Comparación referencial basada en medidas mínimas de piscina olímpica

INTELIGENCIA ARTIFICIAL PARA UNA GESTIÓN EFICIENTE Y SOSTENIBLE DEL AGUA

Poseidón es la plataforma central de Ainwater para monitoreo y análisis en tiempo real.

En plantas reales ha permitido reducir los costos operativos hasta en un 30%.




Captura Referencial de Plataforma Poseidón

CONTROL MANUAL DE DATOS AFECTA LA CONFIABILIDAD DE LOS MODELOS

El control de calidad de datos en las plantas es hoy un proceso **manual, lento y reactivo**.


Los **outliers** y **drift** pueden pasar desapercibidos por largos periodos, afectando la estabilidad operativa y aumentando los costos.




Wired español artículo sobre Ainwater

CONTROL MANUAL DE DATOS AFECTA LA CONFIABILIDAD DE LOS MODELOS

Outliers: valores o grupos de puntos que se alejan drásticamente del comportamiento normal del sensor.




Drift: cambio sostenido en la distribución del sensor a lo largo del tiempo.



Imágenes Referenciales (no corresponden a datos reales de Ainwater)

SERIES DE TIEMPO MULTIVARIABLES DE SENSORES EN PLANTAS DE TRATAMIENTO




Las plantas generan series minuto a minuto que combinan múltiples sensores con niveles de variabilidad distintos.

Procesarlas según su comportamiento histórico es esencial para evitar interpretar ruido como anomalías.

PATRONES OPERATIVOS EN LOS SENSORES: VARIABLES CÍCLICAS

Algunas variables presentan comportamientos cíclicos asociados a la operación diaria de la planta.

Estos ciclos pueden generar oscilaciones regulares que no corresponden a anomalías, sino a patrones naturales de funcionamiento.




Variables reales presentes en los datos de estudio

PATRONES OPERATIVOS EN LOS SENSORES: TRAMOS ESTABLES

Otras variables mantienen tramos prolongados en valores casi constantes o mesetas, reflejando etapas estables del proceso.

Estos periodos pueden incluir picos, ruidos o pequeñas fluctuaciones sin implicar un cambio real en la operación.




Variables reales presentes en los datos de estudio

DATOS ETIQUETADOS PARA VALIDAR LOS MODELOS: OUTLIERS

Para outliers, se utilizaron **datos reales** de las tres plantas, que fueron revisados y etiquetados manualmente para identificar valores anómalos y nubes de outliers.


Estas etiquetas sirvieron como base para evaluar el desempeño del modelo bajo condiciones operacionales reales.



DATOS ETIQUETADOS PARA VALIDAR LOS MODELOS: DRIFT

En el caso del drift, se generaron **datos sintéticos** con cambios controlados en la distribución del sensor, tanto abruptos como graduales.


Estos episodios fueron etiquetados manualmente y permitieron comparar estrategias de referencia y validar la detección del cambio en distintos escenarios.




SISTEMA AUTOMÁTICO PARA DETECTAR OUTLIERS Y DRIFT EN SERIES HISTÓRICAS

El sistema procesa series históricas minuto a minuto y aplica dos pipelines separados según el tipo de detección requerido.

Cada módulo realiza su propio preprocesamiento, cálculo y genera un archivo etiquetado.




UTILIZAR MODELOS DE SERIE DE TIEMPO PARA DETECTAR ANOMALÍAS



Takeuchi and Yamanishi, 2006 A unifying framework for detecting outliers


UTILIZAR DIFERENCIACIÓN CENTRADA PARA DETECTAR ANOMALÍAS




Palma, W. (2016). Time Series Analysis

IMPLEMENTACIÓN DE MÉTODOS AUTOMÁTICOS PARA DETECTAR OUTLIERS EN SERIES DE TIEMPO

- Diferenciación estadística, para identificar variaciones bruscas respecto al histórico



- Modelos AR(2), que aprenden patrones temporales y marcan desviaciones significativas como outliers



Variables reales presentes en los datos de estudio

UTILIZAR COMPARACIONES ENTRE VENTANAS PARA MEDIR CAMBIOS SOSTENIDOS EN LA DISTRIBUCIÓN

El módulo compara cada ventana actual con una **ventana de referencia** del historial para medir cambios sostenidos en la distribución.

Un **método estadístico** genera un drift score que se compara con un **threshold** para decidir si existe un episodio de drift.



SELECCIONAR LA REFERENCIA HISTÓRICA CORRECTA PARA COMPARAR LA VENTANA ACTUAL

Decay (exponencial)

La referencia prioriza los datos más recientes mediante pesos decrecientes.
Se adapta rápido a cambios graduales del sensor.

Golden

La referencia se construye usando periodos históricos especialmente estables.
Ideal para sensores con comportamiento muy limpio y poco ruido.

Seasonal

La referencia utiliza ciclos pasados en la misma fase.
Evita falsos positivos en variables periódicas o cíclicas.

CUANTIFICAR EL CAMBIO ENTRE LA VENTANA ACTUAL Y LA REFERENCIA MEDIANTE MÉTODOS ESTADÍSTICOS

Wasserstein Distance

Mide cuánto debe “moverse” una distribución para transformarse en la otra.

Robusto y sensible a cambios graduales o de forma.

KS (Kolmogorov–Smirnov)

Compara la máxima diferencia entre distribuciones acumuladas.

Muy efectivo detectando cambios abruptos.


PSI (Population Stability Index)

Evalúa variaciones en la forma general de la distribución.


Detecta bien cambios progresivos o de tendencia.

IMPLEMENTACIÓN DE MÉTODOS AUTOMÁTICOS PARA DETECTAR DRIFT EN SERIES DE TIEMPO

Drift gradual detectado a través del cambio sostenido en la distribución. El sistema marca un episodio continuo de drift en la zona roja.



Drift abrupto, identificado en la primera ventana que supera el threshold. El salto en la distribución provoca un cambio brusco en el drift score.



Variables reales presentes en los datos de estudio

MÉTRICAS BÁSICAS PARA EVALUAR LA CALIDAD DE LAS DETECCIONES

Precision

Indica qué tan confiables son las detecciones.

De todo lo que el modelo marcó como anómalo, cuántas detecciones fueron correctas.

Recall

Mide la capacidad para encontrar episodios reales.

De todos los cambios que realmente ocurrieron, cuántos detectó.

F1-score

Equilibrio entre Precision y Recall.

Resume qué tan bien detecta sin generar demasiadas falsas alarmas.

EVALUAR LA DETECCIÓN DE DRIFT CON MÉTRICAS BASADAS EN CONTINUIDAD TEMPORAL

FI time

Evalúa cuánta parte del episodio completo fue detectada.

Considera continuidad y duración del drift, no solo un punto aislado.

FI mixto

Combina FI tradicional con FI time. Métrica más representativa para drift sostenido: mide exactitud y cobertura temporal.



Almeida et al. (2021). On the importance of early drift detection.
Baena-García et al. (2006). Early Drift Detection Method (EDDM).

IMPLEMENTACIÓN DE MÉTODOS AUTOMÁTICOS PARA DETECTAR ANOMALÍAS EN SERIES DE TIEMPO

■ Modelo Diferenciación estadística


Variable	Precisión	Recall	F1-Score
pH coagulación entrada DAF	0.579	0.846	0.688
pH Clarificado DAF (Tk_80m3)	0.667	0.667	0.667
pH salida a Parshall 02	0.500	1.000	0.667
Flujo Salida de Lodo Sed. Sec. 3	0.692	0.964	0.806
Flujo Afluente PTAR	1.000	0.500	0.667
Flujo Cámara de contacto 2	1.000	0.500	0.667

■ Modelo AR

Variable	Precisión	Recall	F1-Score
pH coagulación entrada DAF	0.455	0.769	0.572
pH Clarificado DAF (Tk_80m3)	0.286	1.000	0.445
pH salida a Parshall 02	0.000	0.000	0.000
Flujo Salida de Lodo Sed. Sec. 3	0.789	0.536	0.638
Flujo Afluente PTAR	0.118	1.000	0.211
Flujo Cámara de contacto 2	0.105	1.000	0.190

COMPARACIÓN DE MÉTODOS Y ESTRATEGIAS PARA DETECTAR DRIFT

Visualización del desempeño usando FI Mixto para distintos tamaños de ventana.



Resultados para Ventana de 36 horas.

Método	Estrategia	FI	FI time	FI mixto
KS	Decay	1.000	0.532	0.929
KS	Golden	0.978	0.634	0.906
PSI	Decay	1.000	0.527	0.929
PSI	Golden	1.000	0.645	0.945
Wasserstein	Decay	1.000	0.534	0.930
Wasserstein	Golden	1.000	0.635	0.953

Se omiten los resultados de método Seasonal por su inferior rendimiento

HACIA UNA MEJOR DETECCIÓN DE OUTLIERS Y DRIFT

Outliers:

Se puede mejorar ajustando un modelo de serie de tiempo más adecuado por variable.

Para el algoritmo de diferenciación se podría buscar un mejor umbral que la desviación estándar .

Drift:

Los métodos estadísticos podrían ajustarse mejorando la sensibilidad del threshold para detectar drifts más suaves.

Es posible optimizar la continuidad temporal ajustando FI Time y FI Mixto para reducir detecciones parciales o tardías.

RESULTADOS GLOBALES Y LÍNEAS DE DESARROLLO FUTURAS

- La arquitectura modular deja una base sólida para futuras extensiones, permitiendo agregar nuevos métodos, estrategias y datos sin modificar el pipeline principal.
- Validación con datos reales de planta, incorporando episodios etiquetados por operadores para ajustar sensibilidad, umbrales y estrategias de referencia.
- Ejecución en tiempo real dentro de Poseidón, integrando ventanas deslizantes continuas y actualización dinámica de referencias para un monitoreo online.



OPTIMIZACIÓN DE MODELOS PREDICTIVOS MEDIANTE DETECCIÓN DE OUTLIERS Y DRIFT

FRANCO CHIAPPE

VICENTE GARAY

ZIYU GUO